TRƯỜNG ĐẠI HỌC VĂN LANG
KHOA CÔNG NGHỆ THÔNG TIN

TRẦN LÊ GIA HIẾU – 207CT55050

KHÓA LUẬN TỐT NGHIỆP

Mô hình phân cụm dữ liệu để dự báo bài báo mạng

KHÓA LUẬN TỐT NGHIỆP ĐẠI HỌC HỆ CHÍNH QUY

Ngành đào tạo Công nghệ Thông tin (7480201)
Chuyên ngành <Công nghệ Dữ liệu>

Giảng viên hướng dẫn: TS. Trần Ngọc Việt

TP. Hồ Chí Minh – năm 2024

LỜI CẢM ƠN

Tôi muốn gửi lời cảm ơn sâu sắc nhất đến thầy Việt vì đã dành thời gian và tâm huyết để hướng dẫn tôi trong suốt quá trình thực hiện đồ án tốt nghiệp. Sự hướng dẫn, chỉ bảo và động viên của thầy đã giúp tôi hoàn thành khóa luận một cách xuất sắc.

MỤC LỤC

1. Nội dung **7**

1.1. Lý do lựa chọn đề tài **7**

1.2. Đối tượng, phạm vi thực hiện Đề tài **8**

1.2.1. Đối tượng nghiên cứu **8**

1.2.2. Phạm vi thực hiện **8**

1.3. Phương pháp luận được ứng dụng trong Đề tài **8**

1.3.1. Phần mềm **8**

1.3.2. Phần cứng và mạng **8**

1.3.3. Dữ liệu **8**

1.4. Dự kiến kết quả Đề tài **8**

2. Từ khóa phục vụ tra cứu (thuật ngữ): **8**

4. Lời cam đoan của tác giả **9**

5. Thời gian thực hiện Đề tài: **10**

6. Báo cáo giữa kỳ **11**

7. Báo cáo Khóa luận / Đồ án Tốt nghiệp **11**

7.1. Mở đầu **11**

7.2. Mô hình phân tích dữ liệu **11**

7.2.1. Thu thập dữ liệu **11**

7.2.2. Xử lý dữ liệu **12**

7.3. Bài toán học máy phân cụm **22**

7.3.1 Thuật toán K-means: **22**

7.3.3 Khởi tạo centroid tốt hơn với K-means++ **35**

7.4. Kết quả đạt được: **37**

7.4.1 Kết quả phân cụm các bài báo. **37**

7.4.2 Khám phá kết quả phân cụm **40**

7.5. Kết luận và hướng phát triển **46**

7.5.1. Kết luận: **46**

7.5.2. Hướng phát triển: **46**

7.6. Mã nguồn, dữ liệu, giải thuật, đóng gói phần mềm: **52**

7.6.1. Xử lý và demo thuật toán với Jupyter Notebook: **52**

7.6.2. Demo trên Python Flask: **62**

7.7 Tài liệu tham khảo **67**

7.8 Xác nhận của Giảng viên Hướng dẫn, Bộ môn phụ trách **68**

MỤC LỤC HÌNH

Hình 1. Import thư viện 12
Hình 2. Load dữ liệu thành SFrame (Như dataframe) 12
Hình 3. Sơ lược về dữ liệu tổng 13
Hình 4. Bỏ dữ liệu rỗng 14
Hình 5. Tạo dataset1 14
Hình 6. Xem thử cột Topic 14
Hình 7. Lấy dữ liệu dataset 2 dựa vào 4 chủ đề 15
Hình 8. Kiểu dữ liệu giữa 2 dataset cùng với số lượng dữ liệu mỗi dataset 15
Hình 9. Show ra dữ liệu trong 2 dataset đó 16
Hình 10. Sử dụng hàm tính tfidf và word_count 16
Hình 11. Kết quả cột word_count và tfidf 18
Hình 12. PCA nén dữ liệu nhiều chiều thành ma trận 2x2 19
Hình 13. Tạo hàm để vẽ dữ liệu word_count và tfidf 20
Hình 14. Kết quả trực quang dữ liệu 21
Hình 15. Trực quang hóa dữ liệu 3 chiều 26
Hình 16. Iteration 1 28
Hình 17. Trực quan hóa Iteration 2 30
Hình 18. Trực quan hóa k-means với khởi tạo centroid khác 31
Hình 19. Minh họa các khoảng cách đến centroid 33
Hình 20. Overfitting dữ liệu mức cao nhất 33
Hình 21. Heterogeneity so với số K 34
Hình 22. Heterogeneity so với số Iteration 34
Hình 23. Minh họa K-means++ bước 1 36
Hình 24. Minh họa K-means++ bước 2 36
Hình 25. Minh họa K-means++ bước 3 37
Hình 26. So sánh kết quả giữa 2 dataset trong ở dataset báo mạng Vietnam 38
Hình 27. Cluster 0 trong dataset1 40
Hình 28. Cluster 1 trong dataset1 41
Hình 29. Cluster 2 trong dataset1 42
Hình 30. Cluster 0 trong dataset2 43

Hình 31. Cluster 1 trong dataset2 44
Hình 32. Cluster 2 trong dataset2 45
Hình 33. Mô hình Map Reduce [5] 46
Hình 34. Trang chủ Index 48
Hình 35. Trang K-means 48
Hình 36. Ví dụ bài báo ngẫu nhiên với K=3 49
Hình 37. Mở rộng của một bài báo gần trung tâm cluster 49
Hình 38. Thêm 1 ví dụ khác nằm trong cluster khác 50
Hình 39. Ví dụ thêm 50
Hình 40. Ví dụ với K=75 51
Hình 41. Query khác với K=75 51
Hình 42. Mã nguồn Notebook 1 52
Hình 43. Mã nguồn Notebook 2 53
Hình 44. Mã nguồn Notebook 3 54
Hình 45. Mã nguồn Notebook 4 55
Hình 46. Mã nguồn Notebook 5 56
Hình 47. Mã nguồn Notebook 6 57
Hình 48. Mã nguồn Notebook 7 58
Hình 49. Mã nguồn Notebook 8 59
Hình 50. Mã nguồn Notebook 9 60
Hình 51. Mã nguồn Notebook 10 61
Hình 52. Mã nguồn Python Flask 1 62
Hình 53. Mã nguồn Python Flask 2 63
Hình 54. Mã nguồn Python Flask 3 64
Hình 55. Mã nguồn Python Flask 4 65
Hình 56. Mã nguồn file index.html 66
Hình 57. Mã nguồn file home_kmean.html 66

MỤC LỤC BẢNG

Bảng 1. Các bài báo tượng trưng 23
Bảng 2. Ma trận phân bố chữ 24
Bảng 3. Bảng tính Term Frequency cho dữ liệu mẫu 24
Bảng 4. Giá trị IDF cho từng từ 25
Bảng 5. Kết quả tính TF-IDF cho từng chữ với từng bài báo 25
Bảng 6. Khoảng cách Euclid các điểm đến các trung tâm 26
Bảng 7. Gán điểm khảo sát vào trung tâm gần nhất 27
Bảng 8. Chỉnh lại centroid vào trung tâm cluster 27
Bảng 9. Khoảng cách các bài báo đến centroid mới 28
Bảng 10. Gán điểm khảo sát cho centroid gần nó nhất cho lần lặp thứ 2 29
Bảng 11. Gán lại vị trí các centroid cho lần lặp thứ 2 29
Bảng 12. Kết quả phân cụm sau khi K-means 30
Bảng 13. Kết quả vị trí các centroid cuối cùng với cách khởi tạo centroid khác 32
Bảng 14. Kết quả phân cụm sau các khởi tạo centroid khác 32
Bảng 15. Bảng so sánh mức đồng nhất giữa 2 tệp dữ liệu qua các số k khác nhau 39

1. Nội dung

1.1. Lý do lựa chọn đề tài

Xu thế công nghệ thông tin hiện nay đang trong thời kỳ đổi mới, bước chuyển lớn thiên về xử lý và sử dụng dữ liệu. Điểm nhấn mạnh mẽ nhất trong thời kỳ này là sự phát triển rất mạnh mẽ của lĩnh vực liên quan đến học máy và A.I, cũng như mới hơn gần đây là lĩnh vực Generative A.I có thể nhanh chóng tạo chữ, hình, hay cả âm thanh chỉ qua vài từ khóa người dùng nhập vào. Đây là một cột mốc quan trọng mà ta đặt tên là thời kỳ số hóa cũng như chuyển đổi số.

Một trong những thành tựu trước thời kỳ này là lĩnh vực học máy (Machine Learning) là nền móng để phát triển mọi thuật toán cũng như ứng dụng xử lý dữ liệu và A.I hiện nay. Học máy là một lĩnh vực rất quan trọng, đưa ra rất nhiều trí tuệ qua những dữ liệu lớn. Các thuật toán liên quan đến học máy ảnh hưởng ít nhiều đến hầu hết mọi quyết định và xu hướng của công nghệ hiện nay, cũng như được tìm thấy trong rất nhiều ứng dụng thường ngày mà ta trong thời đại số hóa sử dụng. Các phần mềm như Google dịch, Spotify, camera nhận diện khuôn mặt đều có xuất nguồn từ học máy.

Học máy thường được phân ra thành 3 loại: có giám sát, không có giám sát và học máy tăng cường. Các loại học máy được sử dụng rộng rãi trong rất nhiều ứng dụng hiện nay thường được biểu diễn dưới dạng là mô hình hồi quy để dự đoán giá cả nhà ở, đây là một ứng dụng trong học máy có giám sát. Phân loại rồi dự đoán mức hài lòng của khách hàng dựa vào review họ để lại là một ứng dụng khác của học máy có giám sát.

Lịnh vực học máy không có giám sát cũng không kém phần quan trọng, không bị ràng buộc bởi việc dữ liệu phải được dán nhãn đầy đủ, học máy không giám sát sẽ tự động phân loại và nhóm các tập dữ liệu lại với nhau. Học máy không giám sát là một lựa chọn hấp dẫn nếu ta muốn khám phá một tập dữ liệu, tìm mối tương quan hay khát nhau, cũng như đề nhãn cho tập dữ liệu đó.

Một vấn đề trong lĩnh vực học máy không có giám sát ảnh hưởng rất lớn đến là cách con người hiện nay tiêu thụ các giải trí trên mạng. Câu hỏi được đặt ra là làm cách nào doanh nghiệp tăng thời gian sử dụng của người tiêu thụ. Một giải pháp đề ra dễ thấy chính là hãy cho người dùng xem thêm những nội dung mà họ thích. Các nhà nghiên cứu đã sử dụng học máy phân loại, phân cụm (Clustering) trong học máy không giám sát phân cụm các bài đọc diễn đàn hay tin tức trên mạng. Từ đó tìm những bài viết nào gần giống nhau để tiếp tục hỗ trợ và giúp đỡ người dùng đọc thêm thông tin liên quan đến bài đọc trước đó. Trong nhiều năm qua đã có rất nhiều đề xuất để giải quyết vấn đề này, mới nhất có dụng lĩnh vực LLM (Large Language Model), lựa chọn những model lớn đến hỗ trợ việc phân loại các bài báo tin tức. Hoặc đơn giản hơn sẽ sử dụng những mô hình toán học đến phân loại các bài báo đó hoặc qua những mô hình máy học như Naïve Bayes, K-means, BIRCH…

Với sự phát triển mạnh mẽ của học máy trong thời kỳ số hóa và chuyển đổi số, việc phân loại nội dung của một bài báo mạng, một bài tin tức là một nền móng của lĩnh vực giải trí mạng. Vì vậy tôi đã chọn đề tài này để tìm hiểu và xây dựng một hệ thống tự động phân loại và gợi ý các bài báo tin tức trên mạng.

Trong bài báo cáo này, tôi sẽ thực hiện học máy phân cụm sử dụng thuật toán K-means.

1.2. Đối tượng, phạm vi thực hiện Đề tài

1.2.1. Đối tượng nghiên cứu

Tổng hợp nội dung các bài báo được sưu tầm trên mạng, tin tức từ các trang mạng Việt Nam như báo Tuổi Trẻ, Thanh Niên …

1.2.2. Phạm vi thực hiện

Các bài báo phải sử dụng Tiếng cho người Việt đọc. Bộ dữ liệu chỉ có phạm vi vào tháng 7 năm 2022

1.3. Phương pháp luận được ứng dụng trong Đề tài

1.3.1. Phần mềm

Để xây dựng hệ thống phân loại và gợi ý cho bài báo mạng, tôi sẽ sử dụng các phần mềm Python. Đây là ngôn ngữ được sử dụng để phát triển hệ thống, tôi sẽ sử dụng các thư viện như Turicreate, Numpy, Pyplot để hỗ trợ việc phân tích dữ liệu học máy.

1.3.2. Phần cứng và mạng

Để đảm bảo tính ổn định và tốc độ cao cho hệ thống, chúng tôi sẽ cần một máy vi tính để làm máy chủ. Máy tính này cần có cấu hình tốt để đảm bảo tốc độ xử lý và lưu trữ dữ liệu. Máy tính cần có mạng ổn định để đảm bảo truy cập từ xa và truyền tải dữ liệu giữa các thành phần của hệ thống.

1.3.3. Dữ liệu

Dữ liệu đầu vào cho hệ thống sẽ được lấy từ các diễn đàn trực tuyến, bao gồm cả nội dung của bài viết và thông tin về người đăng. Chúng tôi sẽ phải xử lý và tạo ra các tập dữ liệu để luyện và kiểm thử hệ thống.

1.4. Dự kiến kết quả Đề tài

Dự kiện kết quả của đề tài sẽ cho ra một sản phẩm là phần mềm hoặc trang web có thể gợi ý một bài báo cho người đọc và gợi ý các bài báo tương tự có tính liên quan, tăng mức độ hứng thú cao hơn cho người đọc.

2. Từ khóa phục vụ tra cứu (thuật ngữ):

DATA: Dữ liệu là một tập hợp các thông tin được tổ chức theo một cấu trúc nhất định, được sử dụng để lưu trữ và quản lý thông tin.

AI (Artificial Intelligence): AI là một lĩnh vực của máy tính nghiên cứu về việc tạo ra các hệ thống máy tính có khả năng suy nghĩ và hành động giống như con người.

ML (Machine Learning): Học máy là một lĩnh vực trong AI về việc phát triển các hệ thống máy tính có khả năng học từ dữ liệu và cải thiện hiệu suất của mình dựa trên kinh nghiệm trước đó.

CLUSTER: Một cụm dữ liệu.

4. Lời cam đoan của tác giả

Sinh viên (Nhóm sinh viên) cam đoan không sao chép, trích dẫn toàn văn các tài liệu, văn bản, công trình nghiên cứu của người khác đã công bố, được truy cập từ mạng Internet mà không ghi rõ xuất xứ trong Báo cáo Đề tài. Ghi rõ địa điểm, ngày tháng và họ tên từng sinh viên là tác giả của Báo cáo Đề tài.

Người thực hiện



Trần Lê Gia Hiếu

5. Thời gian thực hiện Đề tài:

14 tuần, bắt đầu từ tháng **01/03/2024**, kết thúc **20/06/2024**.

6. Báo cáo giữa kỳ

Theo kế hoạch của Bộ môn, Thời hạn chậm nhất **30/04/2024**

7. **Báo cáo Khóa luận / Đồ án Tốt nghiệp**

7.1. Mở đầu

Trong báo cáo này, tôi sẽ trình bày về cách áp dụng các thuật toán học máy phân cụm dữ liệu vào bộ dữ liệu báo mạng ở các trang tin tức Việt Nam. Dữ liệu báo mạng là một trong những nguồn dữ liệu lớn mà người dân Việt Nam được tiếp xúc đến, và việc phân tích dữ liệu này có giá trị rất lớn với thời đại số hóa, giúp cho các doanh nghiệp xây dựng các ứng dụng cạnh tranh mức về mức độ tập trung của người dùng. Trong báo cáo này, tôi sẽ tập trung vào việc áp dụng thuật toán phân cụm phổ biến là K-means vào dữ liệu tin tức tiếng Việt, và đánh giá hiệu suất của các thuật toán này trong việc phân cụm dữ liệu.

7.2. Mô hình phân tích dữ liệu

7.2.1. Thu thập dữ liệu

Việc chọn và thu thập dữ liệu rất quan trọng cho lĩnh vực khoa học dữ liệu. Ta phải xem dữ liệu có phù hợp với mục tiêu sử dụng hay không, độ lớn dữ liệu cũng như chất lượng của bộ dữ liệu đó. Dữ liệu đầu vào được sử dụng phải đạt các tiêu chí sau: Có toàn bộ dữ liệu các bài báo mạng bằng tiếng Việt, có gắn nhãn chủ đề sẽ giúp công việc xử lý dữ liệu dễ dàng hơn. Vì vậy tôi đã chọn một bộ dữ liệu trên Kaggle làm dữ liệu chính để phân tích và phân cụm. Bộ dữ được thu thập bởi "HAITRANQUANG-OFFICIAL" một người dùng trên Kaggle và được đặt tên là "Vietnamese Online News Dataset". Chứa dữ liệu của 25 trang web tin tức mạng khác nhau tại Việt Nam trong tháng 7 năm 2022.

Trong đó tập có chứa 10 trường dữ liệu sau đây: "Id", "Author" (Tên tác giả), "Title" (Tên bài báo) "Content" (Nội dung bài báo), "Picture Count" (Số lượng hình ảnh), "Topic" (Chủ đề bài báo), "URL" (Đường dẫn của bài báo), "Source" (Tên trang chủ phát hành bài báo), "Crawled At" (Thời điểm bài báo được thu thập) và "Processed" (Đã qua xử lý hay chưa). Toàn bộ dữ liệu chứa tổng cộng 180000 bài báo. Với số lượng lớn bài báo ta có thể nhận thấy nếu thực hiện các thuật toán như KNN và K-mean, độ phức tạp thời gian của thuật toán sẽ quá lớn để có thể duyệt hết tất cả các bài báo (Độ phức tạp tính gần đúng của KNN là O(n * k) và K-mean là O(n * log(n))).

Vì vậy trước khi xử lý dữ liệu phải có các phương án để xử lý đề này. Theo tôi có 2 cách giải quyết: Nếu độ phức tạp lớn thì ta có thể giảm số lượng data xuống hoặc tăng tốc độ xử lý thuật toán lên, vì vậy sau khi xử lý dữ liệu đơn giản nhất tôi sẽ giảm số lượng dữ liệu xuống. Để tăng tốc độ xử lý thuật toán lên, trong mô hình K-mean tôi có thể sử dụng mô hình Map-Reduce để tăng tốc quá trình phân cụm của thuật toán lên (Sẽ đề cập ở chương 3).

7.2.2. Xử lý dữ liệu

a) Tiền xử lý dữ liệu

Ta nạp các thư viện cần thiết cho công việc xử lý dữ liệu của tôi. Các thư viện tôi xử dụng gồm có: Turicreate, numpy, matplotlib, json (*Hình 1*).

```
[17]: import turicreate as tc
      import numpy as np
      import matplotlib.pyplot as plt
      import json
```

Hình 1. Import thư viện

Trước khi xử lýdữ liệu, ta phải xem trước dữ liệu hiện có, sử dụng thư viện Turicreate, tôi đọc dữ liệu bằng lệnh Turicreate.SFrame.read_json() (*Hình 2*).

```
[2]: json_data = tc.SFrame.read_json("news_dataset.json")
     Parsing JSON records from /home/enderu/Downloads/ML-clustering/news_dataset.json
     Successfully parsed 184539 elements from the JSON file /home/enderu/Downloads/ML-clustering/news_dataset.json
```

Hình 2. Load dữ liệu thành SFrame (Như dataframe)

Dữ liệu đưa vào có cấu trúc SFrame tương đương với cấu trúc Dataframe bên Pandas chứa ma trận dữ liệu cùng với label tên cột như, vì vậy các lệnh bên SFrame gần như giống với lại Dataframe. Thấp hơn SFrame là SArray tương đương với Series bên Pandas chứa duy nhất mảng 1 chiều dữ liệu. Tiếp đến tôi thực hiện xem dữ liệu để xem xét và nhận xét. Dữ liệu đọc được chứa tổng cộng 180000 dòng được thu thập từ nhiều nguồn web báo tin tức Việt Nam. Ta để ý ở dòng thứ 8 do tác giả "Hoàng Yến/VOV.VN" dữ liệu "content" chứa thông tin bài báo bị rỗng, nên ta sẽ lưu ý sẽ phải loại bỏ các dữ liệu rỗng. Trong khi thực hiện nhóm các dữ liệu lại, cột dữ liệu quan trọng nhất mà ta cần quan tâm tới chính là cột chứa tất cả các bài báo dưới dạng chữ. Cột đó là cột dữ liệu "content", các thuật toán nhóm dữ liệu đều sẽ dựa vào cột này để xử lý. Ngoài ra còn một cột khác đáng quan tâm đến là cột "topic" chứa nhãn chủ đề sẵn cho rất nhiều bài báo (*Hình 3* thể hiện sơ bộ dataset thể hiện qua thư viện Turicreate SFrame).

[3]:
```
json_data
```

[3]:

author	content	crawled_at	id	picture_count	processed
	Chiều 31/7, Công an tỉnh Thừa Thiên - Huế đã có ...	2022-08-01 09:09:22.817308 ...	218270	3	0
(Nguồn: Sina)	Gần đây, Thứ trưởng Bộ Phát triển Kỹ thuật số, ...	2022-08-01 09:09:21.181469 ...	218269	1	0
Hồ Sỹ Anh	Kết quả thi tốt nghiệp THPT năm 2022 cho thấy ...	2022-08-01 09:09:15.311901 ...	218268	3	0
Ngọc Ánh	Thống đốc Kentucky Andy Beshear hôm 31/7 cho hay ...	2022-08-01 09:09:02.211498 ...	218267	1	0
HẢI YẾN - MINH LÝ	Vụ tai nạn giao thông liên hoàn trên phố đi bộ ...	2022-08-01 09:09:01.601170 ...	218266	12	0
	Chia sẻ trên Twitter, thị trưởng Hanover Belit ...	2022-08-01 09:09:01.320653 ...	218265	2	0
	"Em vỡ òa trong hạnh phúc khi được xướng tên ở ...	2022-08-01 09:08:57.167808 ...	218264	8	0
Hoàng Yến/VOV.VN		2022-08-01 09:08:51.092437 ...	218263	1	0
T.G	Soi kèo nhà cái Liverpool vs Strasbourg. Nhận đ ...	2022-08-01 09:08:47.355309 ...	218262	3	0
Đỗ Trung	Siêu sao Bồ Đào Nha được HLV Erik ten Hag bố trí ...	2022-08-01 09:08:42.496092 ...	218261	1	0

source	title	topic	url
docbao.vn	Tên cướp tiệm vàng tại Huế là đại uý công an, ...	Pháp luật	https://docbao.vn/phap-luat/ten-cuop-tiem-vang- ...
vtc.vn	Bỏ qua mạng 5G, Nga tiến thẳng từ 4G lên 6G ...	Sống kết nối	https://vtc.vn/bo-qua-mang-5g-nga-tien-than ...
thanhnien.vn	Địa phương nào đứng đầu cả nước tổng điểm 3 môn ...	Giáo dục	https://thanhnien.vn/dia-phuong-nao-dung-dau-ca- ...
vnexpress	Người chết trong mưa lũ 'nghìn năm có một' ở Mỹ ...	Thế giới	https://vnexpress.net/nguoi-chet-trong-mua-lu- ...
soha	Hải Phòng: Hình ảnh xe "điên" gây tai nạn liên ...	Thời sự - Xã hội	https://soha.vn/hai-phong-hinh-anh-xe-dien- ...
tuoitre.vn	Đức có thể suy thoái kinh tế năm nay ...	Thế giới	https://tuoitre.vn/duc-co-the-suy-thoai-kinh ...
baoquocte	Những khoảnh khắc đẹp của Gia Hân khi đăng quang ...	Giải trí	https://baoquocte.vn/nhung-khoanh-khac-dep-cua- ...
vov.vn	Lịch thi đấu vòng 11 V-League 2022: HAGL dễ ...	THỂ THAO	https://vov.vn/the-thao/lich-thi-dau-von ...
thethaovanhoa	Soi kèo nhà cái Liverpool vs Strasbourg. Nhận đ ...		https://thethaovanhoa.vn/du-doan-bong-da/soi-keo- ...
bongdaplus	Bị thay sau hiệp 1, Ronaldo đùng đùng bỏ về ...	Ngoại hạng Anh	https://bongdaplus.vn/ngoai-hang-anh/ronaldo-d ...

[184539 rows x 10 columns]
Note: Only the head of the SFrame is printed.
You can use print_rows(num_rows=m, num_columns=n) to print more rows and columns.

Hình 3. Sơ lược về dữ liệu tổng

b) Làm sạch dữ liệu

Đầu tiên tôi loại bỏ dữ liệu rỗng bằng lệnh dropna() (*Hình 4*)

```
[89]: clean_data = json_data.dropna()
```

Hình 4. Bỏ dữ liệu rỗng

Tôi bắt đầu chia dữ liệu ra thành 2 bộ dữ liệu, bộ dữ liệu 1 có tên là "dataset1" sẽ lấy ngẫu nhiên 2000 phần tử trong bộ dữ liệu sẵn có (*Hình 5*), bộ dữ liệu 1 sẽ tượng trưng là một bộ dữ liệu gồm các bài báo được tổng hợp một cách hỗn loạn.

```
[3]: clean_data = json_data.dropna()
     sample_fraction = 3000 / len(clean_data)

     dataset1 = clean_data.sample(sample_fraction, seed=0)
     dataset1 = dataset1[dataset1['content'].apply(lambda x: x != None and str(x).strip() != '')]
     dataset1 = dataset1[:2000]
```

Hình 5. Tạo dataset1

Bộ dữ liệu 2 có tên là "dataset2" sẽ lấy ngẫu nhiên 2000 phần tử trong bộ dữ liệu sẵn có, bộ dữ liệu 2 sẽ chọn 4 chủ đề trong toàn bộ dữ liệu để làm bộ dữ liệu ổn định (*Hình 6*). Sử dụng lệnh unique() để show ra các chủ đề trong bộ dữ liệu

```
[17]: topic_name = clean_data[['topic']].unique()

[18]: clean_data[['topic']]
```

[18]:

topic
Pháp luật
Sống kết nối
Giáo dục
Thế giới
Thời sự - Xã hội
Thế giới
Giải trí
THỂ THAO
Ngoại hạng Anh

[184120 rows x 1 columns]
Note: Only the head of the SFrame is printed.
You can use print_rows(num_rows=m, num_columns=n) to print more rows and columns.

Hình 6. Xem thử cột Topic

4 chủ đề tôi chọn là “Pháp luật, Giáo dục, Thế giới, Giải trí”. Việc chọn 4 chủ đề cho bộ dữ liệu 2 tôi hi vọng sẽ giúp dữ liệu nhóm cuối cùng sẽ ít hỗn loạn hơn (*Hình 7*).

```
[15]: topics_of_choice = ['Pháp luật', 'Giáo dục', 'Thế giới', 'Giải trí']

dataset2 = clean_data[clean_data['topic'].apply(lambda x: x in topics_of_choice)]
sample_fraction = 3000/ len(dataset2)
dataset2 = dataset2.sample(sample_fraction)
dataset2 = dataset2[dataset2['content'].apply(lambda x: x != None and str(x).strip() != '')]
dataset2 = dataset2[:2000]
```

Hình 7. Lấy dữ liệu dataset 2 dựa vào 4 chủ đề

Kết quả thông số của trường dữ liệu của 2 bộ dữ liệu (*Hình 8 a và b*).

```
[4]: [dataset1]

[4]: [Columns:
        author  str
        content str
        crawled_at      str
        id      int
        picture_count   int
        processed       int
        source  str
        title   str
        topic   str
        url     str

      Rows: 2000
```

a)

```
[dataset2]

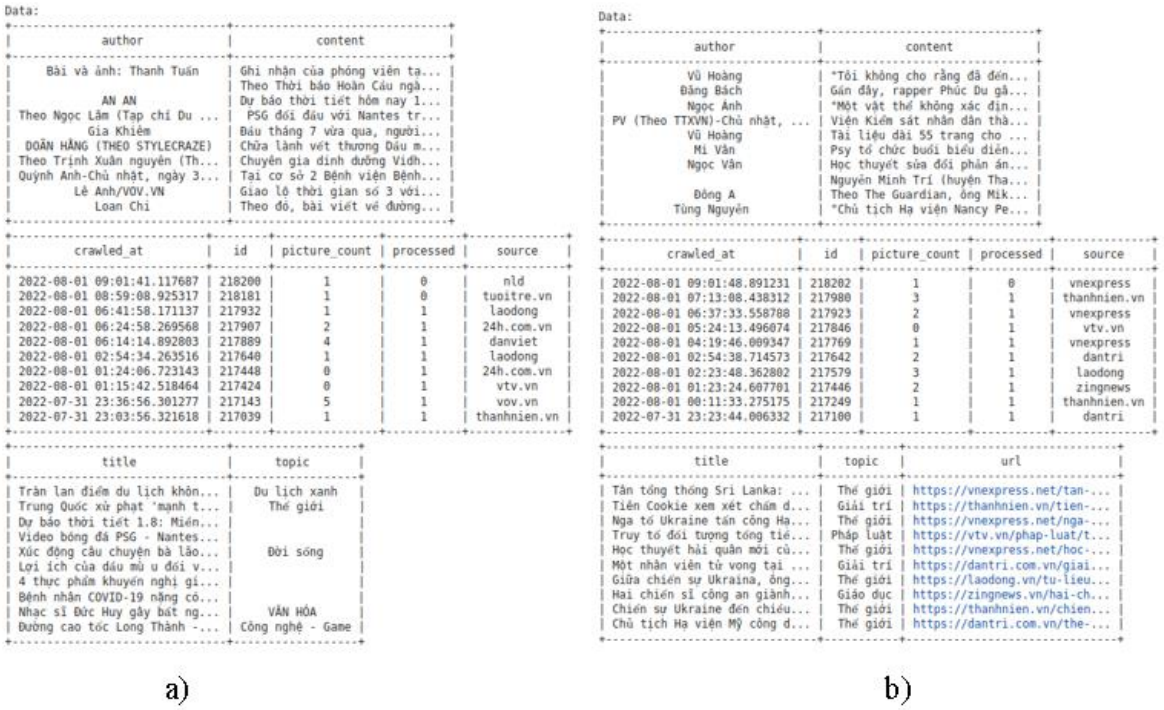
[15]: [Columns:
        author  str
        content str
        crawled_at      str
        id      int
        picture_count   int
        processed       int
        source  str
        title   str
        topic   str
        url     str

      Rows: 2000
```

b)

Hình 8. Kiểu dữ liệu giữa 2 dataset cùng với số lượng dữ liệu mỗi dataset

Kết quả của bộ dữ liệu 1 ở *Hình 9 a)* và bộ dữ liệu 2 ở *Hình 9 b).*



Data:

author	content
Bài và ảnh: Thanh Tuấn	Ghi nhận của phóng viên tạ...
AN AN	Theo Thời báo Hoàn Cầu ngà...
Theo Ngọc Lâm (Tạp chí Du ...	Dự báo thời tiết hôm nay 1...
Gia Khiêm	PSG đối đầu với Nantes tr...
ĐOÀN HẰNG (THEO STYLECRAZE)	Đầu tháng 7 vừa qua, người...
Theo Trịnh Xuân nguyên (Th...	Chữa lành vết thương Dấu m...
Quỳnh Anh-Chủ nhật, ngày 3...	Chuyên gia dinh dưỡng Vidh...
Lê Anh/VOV.VN	Tại cơ sở 2 Bệnh viện Bệnh...
Loan Chi	Giao lộ thời gian số 3 với...
	Theo đó, bài viết về đường...

crawled_at	id	picture_count	processed	source
2022-08-01 09:01:41.117687	218200	1	0	nld
2022-08-01 08:59:08.925317	218181	1	0	tuoitre.vn
2022-08-01 06:41:58.171137	217932	1	1	laodong
2022-08-01 06:24:58.269568	217907	2	1	24h.com.vn
2022-08-01 06:14:14.892803	217889	4	1	danviet
2022-08-01 02:54:34.263516	217640	1	1	laodong
2022-08-01 01:24:06.723143	217448	0	1	24h.com.vn
2022-08-01 01:15:42.518464	217424	0	1	vtv.vn
2022-07-31 23:36:56.301277	217143	5	1	vov.vn
2022-07-31 23:03:56.321618	217039	1	1	thanhnien.vn

title	topic
Tràn lan điểm du lịch khôn...	Du lịch xanh
Trung Quốc xử phạt 'mạnh t...	Thế giới
Dự báo thời tiết 1.8: Miền...	
Video bóng đá PSG - Nantes...	
Xúc động câu chuyện bà lão...	Đời sống
Lợi ích của dâu mũ u đối v...	
4 thực phẩm khuyến nghị gi...	
Bệnh nhân COVID-19 nặng có...	
Nhạc sĩ Đức Huy gây bất ng...	VĂN HÓA
Đường cao tốc Long Thành -...	Công nghệ - Game

Data:

author	content
Vũ Hoàng	"Tôi không cho rằng đã đến...
Đăng Bách	Gần đây, rapper Phúc Du gã...
Ngọc Anh	"Một vật thể không xác địn...
PV (Theo TTXVN)-Chủ nhật, ...	Viện Kiểm sát nhân dân thà...
Vũ Hoàng	Tài liệu dài 55 trang cho ...
Mi Vân	Psy tổ chức buổi biểu diễn...
Ngọc Vân	Học thuyết sửa đổi phán án...
	Nguyễn Minh Trí (huyện Tha...
Đông A	Theo The Guardian, ông Mik...
Tùng Nguyễn	"Chủ tịch Hạ viện Nancy Pe...

crawled_at	id	picture_count	processed	source
2022-08-01 09:01:48.891231	218202	1	0	vnexpress
2022-08-01 07:13:08.438312	217980	3	1	thanhnien.vn
2022-08-01 06:37:33.558788	217923	2	1	vnexpress
2022-08-01 05:24:13.496074	217846	0	1	vtv.vn
2022-08-01 04:19:46.009347	217769	1	1	vnexpress
2022-08-01 02:54:38.714573	217642	2	1	dantri
2022-08-01 02:23:48.362802	217579	3	1	laodong
2022-08-01 01:23:24.607701	217446	2	1	zingnews
2022-08-01 00:11:33.275175	217249	1	1	thanhnien.vn
2022-07-31 23:23:44.006332	217100	1	1	dantri

title	topic	url
Tân tổng thống Sri Lanka: ...	Thế giới	https://vnexpress.net/tan-...
Tiền Cookie xem xét chấm d...	Giải trí	https://thanhnien.vn/tien-...
Nga tố Ukraine tấn công Ha...	Thế giới	https://vnexpress.net/nga-...
Truy tố đối tượng tống tiề...	Pháp luật	https://vtv.vn/phap-luat/t...
Học thuyết hải quân mới củ...	Thế giới	https://vnexpress.net/hoc-...
Một nhân viên tử vong tại ...	Giải trí	https://dantri.com.vn/giai...
Giữa chiến sự Ukraina, ông...	Thế giới	https://laodong.vn/tu-lieu...
Hai chiến sĩ công an giành...	Giáo dục	https://zingnews.vn/hai-ch...
Chiến sự Ukraine đến chiều...	Thế giới	https://thanhnien.vn/chien...
Chủ tịch Hạ viện Mỹ công d...	Thế giới	https://dantri.com.vn/the-...

a) b)

Hình 9. Show ra dữ liệu trong 2 dataset đó

c) Mã hóa dữ liệu

Thư viện Turicreate hỗ trợ rất nhiều công cụ để thực hiện mã hóa dữ liệu. Các mô hình để nhóm dữ liệu K-mean hay KNN thường sử dụng Bag of Words hoặc TF-IDF để mã hóa. Sử dụng lệnh Turicreate.text_analytics.count_words, và Turicreate.text_analytics.tf-idf để thực hiện mã hóa dữ liệu các bài báo mạng (*Hình 10*).

```
[103]: dataset1['word_count'] = tc.text_analytics.count_words(dataset1['content'])
       dataset1['tfidf'] = tc.text_analytics.tf_idf(dataset1['content'])

[104]: dataset2['word_count'] = tc.text_analytics.count_words(dataset2['content'])
       dataset2['tfidf'] = tc.text_analytics.tf_idf(dataset2['content'])
```

Hình 10. Sử dụng hàm tính tfidf và word_count

2 phương thức mã hóa sẽ biểu thị dữ liệu chữ trong bài báo khác nhau:

- Phương thức Bag of Words:
  - Bỏ qua thứ tự chữ xuất hiện trong bài báo
  - Đếm số lần chữ đó xuất hiện trong bài báo hiện tại rồi lưu lại dưới dạng từ điển.

- Bag of Words sẽ tính điểm cao hơn với các chữ xuất hiện nhiều trong bài báo. Các chữ hiếm quan trọng sẽ trả điểm về thấp hơn như chữ "và", "các" sẽ xuất hiện nhiều và đạt điểm cao hơn so với chữ như tên tuyển thủ bóng đá, hay các chữ hàn lâm.

- Phương thức TF-IDF:
  - Sẽ chấm điểm cao cho các chữ quan trọng trong tất cả bài báo, và tính điểm thấp hơn cho các chữ xuất hiện nhiều trong toàn bộ dữ liệu các bài báo.
  - TF-IDF hay còn gọi là Term Frequency – Inverse Document Frequency. Trong đó Term Frequency là tổng cộng số lần một chữ xuất hiện trong một bài báo và Inverse Document Frequency được tính bằng Log ($\frac{tất\ cả\ các\ bài\ báo}{số\ bài\ báo\ chữ\ xuất\ hiện}$). Từ đó TF-IDF được tính bằng TF x IDF.
  - TF-IDF chính là câu trả lời cho nhược điểm của Bag of Words.
  - Công thức toán học của TF-IDF:

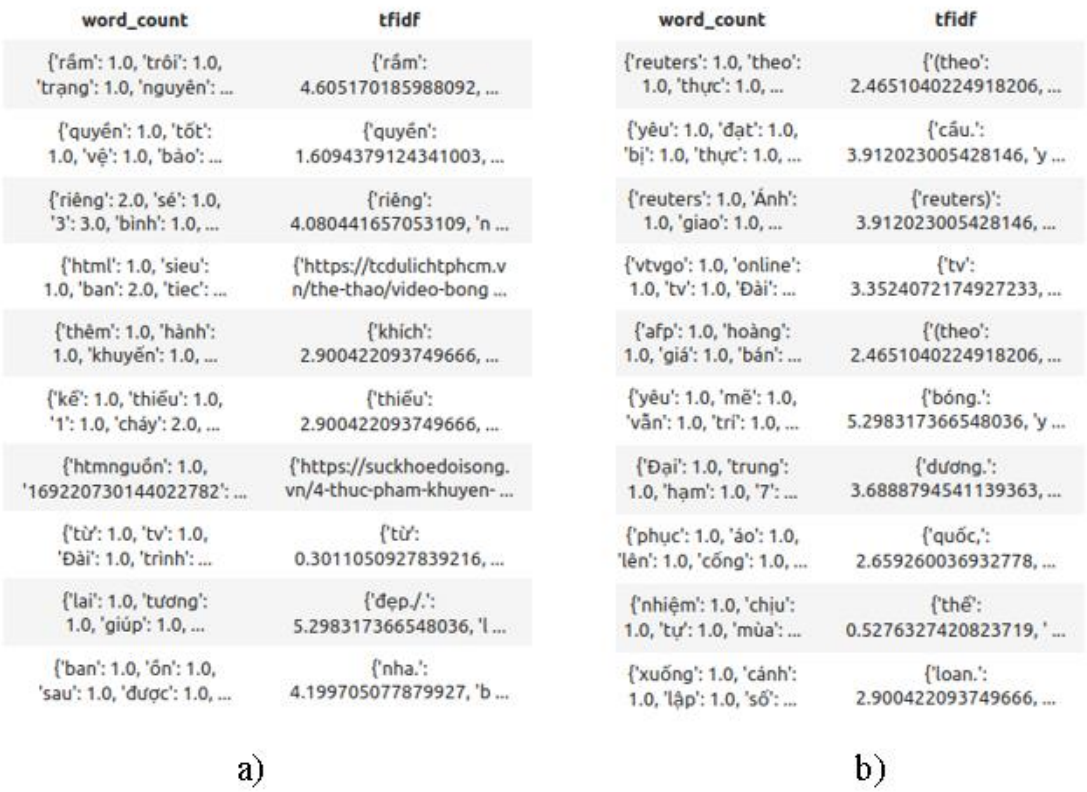
    $$tf - idf_{i,j} = tf_{i,j} \times idf_i$$

    Với

    $$tf_{i,j} = \frac{n_{i,j}}{\sum_k n_{k,j}}$$

    $$idf_i = log \frac{|D|}{|\{d : c_i \in d\}|}$$

Kết quả tạo Bag of Words và TF-IDF cho 2 bộ dữ liệu sẽ là mảng chứa từ điển trong đó các giá trị key là chữ đó và value là điểm trả về của chữ (*Hình 11 a và b*).



word_count	tfidf
{'rằm': 1.0, 'trôi': 1.0, 'trạng': 1.0, 'nguyên': ...	{'rằm': 4.605170185988092, ...
{'quyền': 1.0, 'tốt': 1.0, 'vệ': 1.0, 'bảo': ...	{'quyền': 1.6094379124341003, ...
{'riêng': 2.0, 'sẻ': 1.0, '3': 3.0, 'bình': 1.0, ...	{'riêng': 4.080441657053109, 'n ...
{'html': 1.0, 'sieu': 1.0, 'ban': 2.0, 'tiec': ...	{'https://tcdulichtphcm.vn/the-thao/video-bong ...
{'thêm': 1.0, 'hành': 1.0, 'khuyến': 1.0, ...	{'khích': 2.900422093749666, ...
{'kế': 1.0, 'thiếu': 1.0, '1': 1.0, 'chảy': 2.0, ...	{'thiếu': 2.900422093749666, ...
{'htmnguồn': 1.0, '169220730144022782': ...	{'https://suckhoedoisong.vn/4-thuc-pham-khuyen- ...
{'từ': 1.0, 'tv': 1.0, 'Đài': 1.0, 'trình': ...	{'từ': 0.3011050927839216, ...
{'lại': 1.0, 'tương': 1.0, 'giúp': 1.0, ...	{'đẹp./.': 5.298317366548036, 'l ...
{'ban': 1.0, 'ốn': 1.0, 'sau': 1.0, 'được': 1.0, ...	{'nha.': 4.199705077879927, 'b ...

a)

word_count	tfidf
{'reuters': 1.0, 'theo': 1.0, 'thực': 1.0, ...	{'(theo': 2.4651040224918206, ...
{'yêu': 1.0, 'đạt': 1.0, 'bị': 1.0, 'thực': 1.0, ...	{'cầu.': 3.912023005428146, 'y ...
{'reuters': 1.0, 'Ánh': 1.0, 'giao': 1.0, ...	{'reuters)': 3.912023005428146, ...
{'vtvgo': 1.0, 'online': 1.0, 'tv': 1.0, 'Đài': ...	{'tv': 3.3524072174927233, ...
{'afp': 1.0, 'hoàng': 1.0, 'giá': 1.0, 'bán': ...	{'(theo': 2.4651040224918206, ...
{'yêu': 1.0, 'mẽ': 1.0, 'vẫn': 1.0, 'trí': 1.0, ...	{'bóng.': 5.298317366548036, 'y ...
{'Đại': 1.0, 'trung': 1.0, 'hạm': 1.0, '7': ...	{'dương.': 3.6888794541139363, ...
{'phục': 1.0, 'áo': 1.0, 'lên': 1.0, 'cống': 1.0, ...	{'quốc,': 2.659260036932778, ...
{'nhiệm': 1.0, 'chịu': 1.0, 'tự': 1.0, 'mùa': ...	{'thế': 0.5276327420823719, ' ...
{'xuống': 1.0, 'cảnh': 1.0, 'lập': 1.0, 'số': ...	{'loan.': 2.900422093749666, ...

b)

Hình 11. Kết quả cột word_count và tfidf

d) Hiển thị dữ liệu

Để thực hiện biểu thị dữ liệu, tôi sử dụng hàm PCA trong thư viện sklearn để nén dữ liệu nhiều chiều lại thành 2 chiều để vẽ lên cho từng bài báo (*Hình 12*). Bằng việc biến đổi dữ liệu chữ của từng bài báo thành mảng nhiều chiều (ví dụ như mảng data ở hình) rồi PCA nó thành mảng 2x2 để vẽ đồ thị scatter plot, ta có thể biểu diễn các thông tinh word_count hay tf-idf thành đồ thị.

[128]:
```
from sklearn.decomposition import PCA
test = [{'word1': 10, 'word2': 5, 'word3': 2, 'word4': 3},
                    {'word1': 5, 'word2': 15, 'word3': 3},
                    {'word5': 5, 'word6': 15}]

all_words = set()
for word_count in test:
    all_words.update(word_count.keys())

data = []
for word_count in test:
    row = []
    for word in all_words:
        row.append(word_count.get(word, 0))
    data.append(row)

data = np.array(data)
pca = PCA(n_components=2)
data_pca = pca.fit_transform(data)

data
```

[128]:
```
array([[ 0,  5, 10,  2,  3,  0],
       [ 0, 15,  5,  3,  0,  0],
       [15,  0,  0,  0,  0,  5]])
```

[129]:
```
data_pca
```

[129]:
```
array([[-4.86133194,  6.00284253],
       [-8.67641192, -4.97190871],
       [13.53774386, -1.03093381]])
```

Hình 12. PCA nén dữ liệu nhiều chiều thành ma trận 2x2

Từ đó tôi tạo hàm để vẽ các giá trị đó ra (*Hình 13*):

[125]:
```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.decomposition import PCA

def visualizing_data(word_count_array, plot_name):
    word_count_array  = np.array(word_count_array)

    all_words = set()
    for word_count in word_count_array:
        all_words.update(word_count.keys())

    data = []
    for word_count in word_count_array:
        row = []
        for word in all_words:
            row.append(word_count.get(word, 0))
        data.append(row)

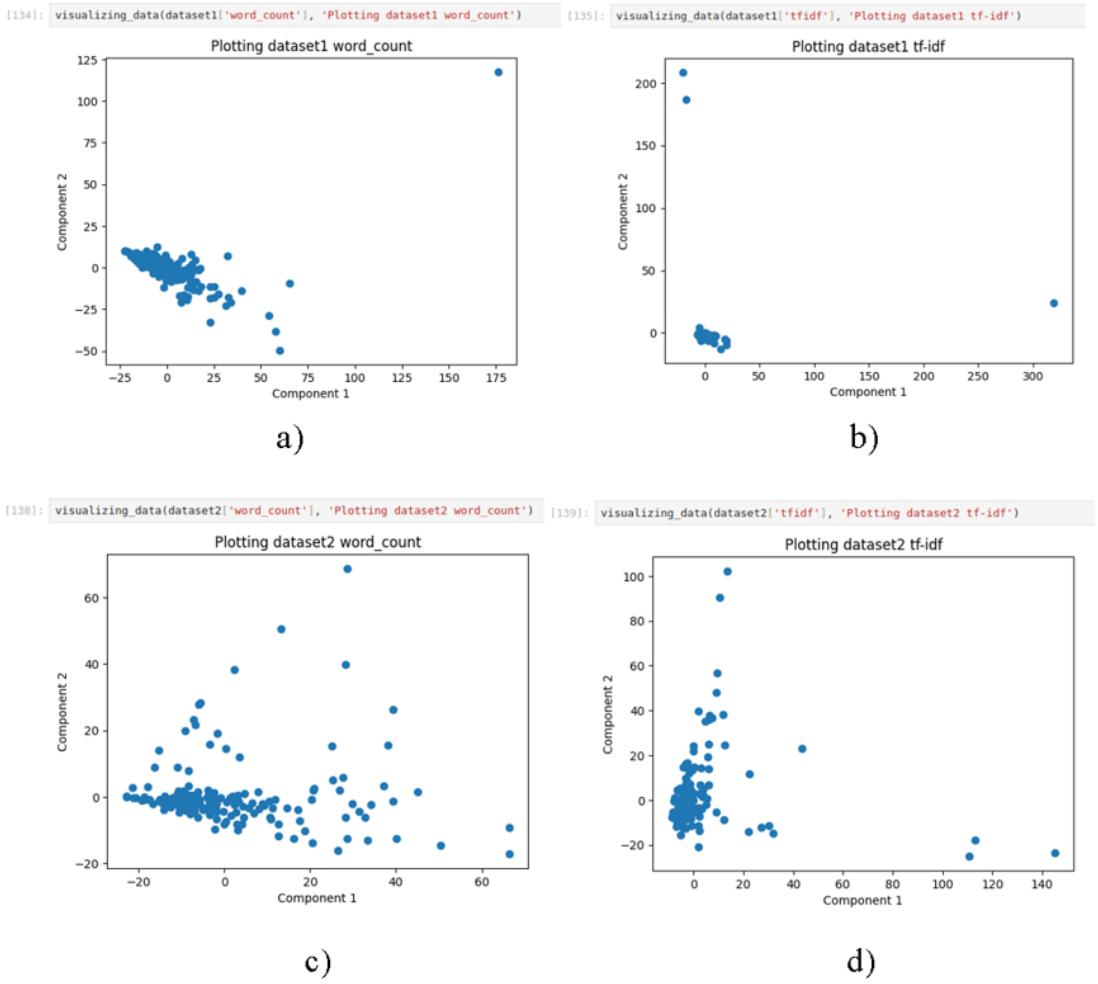
    data = np.array(data)

    pca = PCA(n_components=2)
    data_pca = pca.fit_transform(data)

    plt.scatter(data_pca[:, 0], data_pca[:, 1])
    plt.xlabel('Principal Component 1')
    plt.ylabel('Principal Component 2')
    plt.title(plot_name)
    plt.show()
```

Hình 13. Tạo hàm để vẽ dữ liệu word_count và tfidf

Kết quả của dữ liệu trong dataset1(*Hình 14 a và b*) và dataset2 (*Hình 14 c và d*)



Hình 14. Kết quả trực quan dữ liệu

7.3. Bài toán học máy phân cụm

7.3.1 Thuật toán K-means:

a) Các bước của thuật toán K-means:

Phương thức tính khoảng cách giữa các điểm khảo sát sẽ là khoảng cách Euclid (Euclidian Distance):

$$d(x_2, x_1) = \sqrt{(x_2 - x_1)^2}$$

Bước 1: Khởi tạo các cluster trung tâm

Bước 2: Gán các điểm khảo sát vào cluster trung tâm gần nhất:

$$y_i \leftarrow \text{argmin}_j \left\| x_i - m_j \right\|_2^2$$

Với:

x_i: là điểm khảo sát thứ i

m_j:là điểm cluster trung tâm thứ j

y_i: là nhãn tạo sẵn tùy vào số lượng cluster

argmin_j: trả về chỉ mục j cho các cluster trung tâm gần nhất với điểm khảo sát i

Bước 3: Điều chỉnh lại các cluster trung tâm vào trung bình cộng khoảng cách với các điểm khảo sát nằm gần trung tâm đó:

$$m_j = \frac{1}{n_j} \sum_{i:y_i=j} x_i$$

Với

x_i: là điểm khảo sát thứ i

n_j: là số điểm khảo sát trong cluster trung tâm thứ j

$i: y_i = j$: là số điểm i nằm trong cluster đang xét

Bước 4: Lặp lại bước 2 và 3 đến khi hội tụ (Convergence)

b) Tối ưu thuật toán K-means dưới dạng Coordinate Descent:

Bước 1: Gán các điểm khảo sát vào cluster trung tâm gần nhất:

$$y_i \leftarrow \text{argmin}_j \left\| x_i - m_j \right\|_2^2$$

Bước 2: Điều chỉnh lại các cluster trung tâm vào trung bình cộng khoảng cách với các điểm khảo sát nằm gần trung tâm đó:

$$m_j = \frac{1}{n_j} \sum_{i:y_i=j} x_i$$

Hay: $$m_j \leftarrow \text{argmin}_{m_j} \sum_{i:y_i=j} \|x_i - m_j\|_2^2$$

Ta có thể thấy khi thực hiện tối ưu hóa dưới dạng Coordinate Descent, ta sẽ tối giản hóa 2 phương trình ở bước 1 và 2, với bước 1 sẽ cố định các cluster trung tâm m và thay đổi các điểm đang xét, bước 2 sẽ cố định các điểm đang xét và thay đổi vị trí của các cluster trung tâm. Thuật toán khi hội tụ hoặc đạt điều kiện dừng ta đặt ra (như số lần lặp) sẽ dừng lại.

c) Ví dụ giải thuật K-means:

Giả sử tôi có 5 bài báo như sau:

Bài báo (Articles/Documents)	**Nội dung (Contents)**
1	apple apple banana
2	apple banana banana
3	banana banana banana
4	orange orange orange
5	orange apple orange

Bảng 1. Các bài báo tượng trưng

Viết dưới ma trận phân bố chữ:

Bài báo (Articles/Documents)	apple	orange	banana
1	2	0	1
2	1	0	2
3	0	0	3
4	0	3	0
5	1	2	0

Bảng 2. Ma trận phân bố chữ

Tính TF:

Bài báo (Articles/Documents)	apple	orange	banana
1	2/3	0	1/3
2	1/3	0	2/3
3	0	0	1
4	0	1	0
5	1/3	2/3	0

Bảng 3. Bảng tính Term Frequency cho dữ liệu mẫu

Tính IDF:

Từ	IDF
apple	log(5/4)
orange	log(5/3)
banana	log(5/2)

Bảng 4. Giá trị IDF cho từng từ

Kết quả TF-IDF:

Bài báo (Articles/Documents)	apple	orange	banana
1	0.065	0	0.133
2	0.032	0	0.265
3	0	0	0.398
4	0	0.222	0
5	0.032	0.148	0

Bảng 5. Kết quả tính TF-IDF cho từng chữ với từng bài báo

Thực hiện K-means:

Vòng lặp 0 (Khởi tạo)

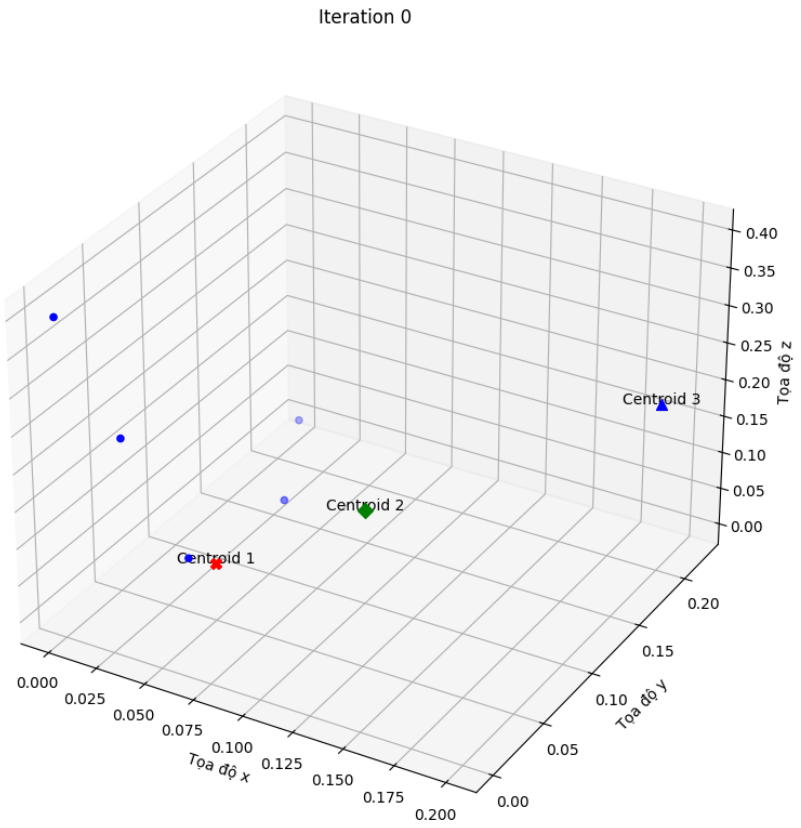
Bước 1: Tạo ngẫu nhiên 3 centroid trung tâm:

$$m_1 = [0.05, 0.05, 0.05]$$

$$m_2 = [0.1, 0.1, 0.1]$$

$$m_3 = [0.2, 0.2, 0.2]$$

Trực quan hóa các điểm khởi tạo so với các điểm quan sát trong đồ thị không gian 3 chiều như *Hình 15.*



Hình 15. Trực quan hóa dữ liệu 3 chiều

Vòng lặp 1 (Iteration 1):

Tính khoảng cách Euclid các centroid đến TF-IDF từng điểm khảo sát với khoảng cách Euclid tại 3 điểm là $D = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2 + (z_2 - z_1)^2}$

Centroid	Bài báo 1	Bài báo 2	Bài báo 3	Bài báo 4	Bài báo 5
m_1	0.098	0.221	0.355	0.186	0.111
m_2	0.111	0.205	0.330	0.187	0.130
m_3	0.250	0.269	0.345	0.284	0.266

Bảng 6. Khoảng cách Euclid các điểm đến các trung tâm

Bước 2: Gán điểm khảo sát vào trung tâm có khoảng cách gần với nó nhất:

Bài báo (Iteration1) (Articles/Documents)	**Centroid gần nhất**	**Khoảng cách Euclid**
1	m_1	0.098
2	m_2	0.205
3	m_2	0.330
4	m_1	0.186
5	m_1	0.111

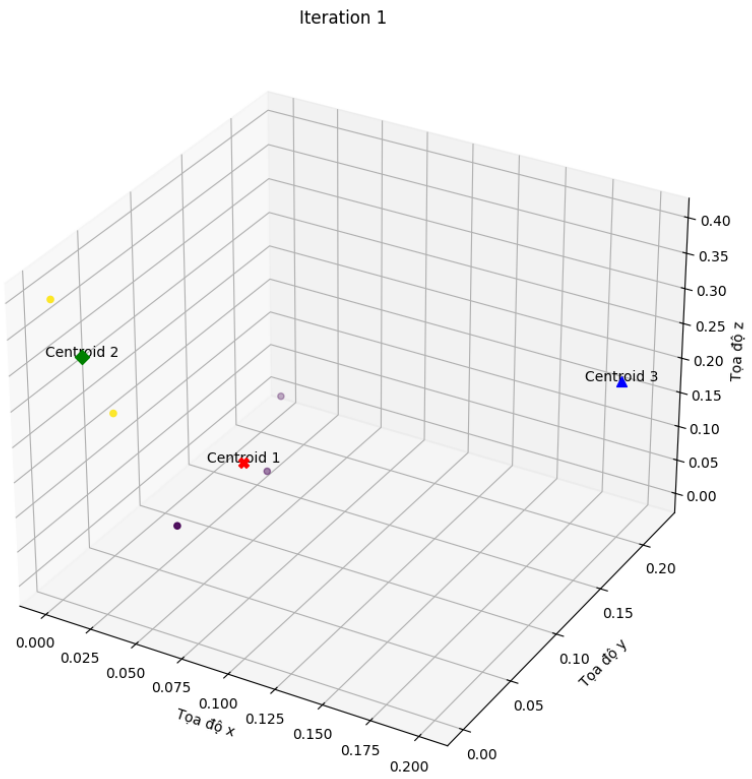
Bảng 7. Gán điểm khảo sát vào trung tâm gần nhất

Bước 3: Điều chỉnh lại các centroid trung tâm lại:

Centroid	**Tọa độ**
m_1	[bài 1 + bài 4 + bài 5]/3 = $[0.0323,\ 0.1233,\ 0.0443]$
m_2	[bài 2 + bài 3]/2 = $[0.0160,\ 0,\ 0.3315]$
m_3	Không thay đổi $= [0.2,\ 0.2,\ 0.2]$

Bảng 8. Chỉnh lại centroid vào trung tâm cluster

Ta trực quan hóa lần lặp thứ nhất lên đồ thị không gian 3 chiều như *Hình 16*



Hình 16. Iteration 1

Bước 4: Lặp lại bước 2 và bước 3 đến khi hội tụ

Vòng lặp 2 (Iteration 2):

Centroid	Bài báo 1	Bài báo 2	Bài báo 3	Bài báo 4	Bài báo 5
m_1	0.155	0.253	0.376	0.113	0.051
m_2	0.204	0.068	0.068	0.399	0.363
m_3	0.250	0.269	0.345	0.284	0.266

Bảng 9. Khoảng cách các bài báo đến centroid mới

Bước 2: Gán điểm khảo sát vào trung tâm có khoảng cách gần với nó nhất:

Bài báo (Iteration 2) (Articles/Documents)	**Centroid gần nhất**	**Khoảng cách Euclid**
1	m_1	0.155
2	m_2	0.068
3	m_2	0.068
4	m_1	0.113
5	m_1	0.051

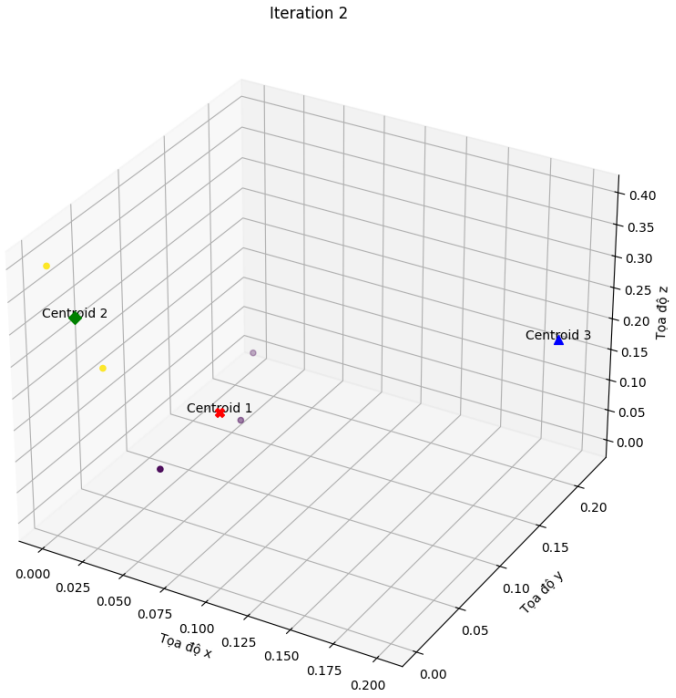
Bảng 10. Gán điểm khảo sát cho centroid gần nó nhất cho lần lặp thứ 2

Bước 3: Điều chỉnh lại các cluster trung tâm lại:

Centroid	**Tọa độ**
m_1	$[0.0323,\ 0.1233,\ 0.0443]$
m_2	$[0.0160,\ 0,\ 0.3315]$
m_3	$[0.2, 0.2, 0.2]$

Bảng 11. Gán lại vị trí các centroid cho lần lặp thứ 2

Ta tiếp tục trực quan hóa lần lặp thứ 2 lên đồ thị không gian 3 chiều như *Hình 17*



Hình 17. Trực quan hóa Iteration 2

Bước 4: Vì các centroid không thay đổi, ta dừng vòng lặp.

Kết quả phân cụm sau khi k-means:

Bài báo (Articles/Documents)	**Thuộc cluster có centroid là**
1	m_1
2	m_2
3	m_2
4	m_1
5	m_1

Bảng 12. Kết quả phân cụm sau khi K-means

Ta nhận thấy tùy vào việc khởi tạo các trung tâm, kết quả phân cụm cũng khác. Trong trường hợp này, centroid m_3 xa các cụm dữ liệu nên không được sử dụng làm trung tâm.

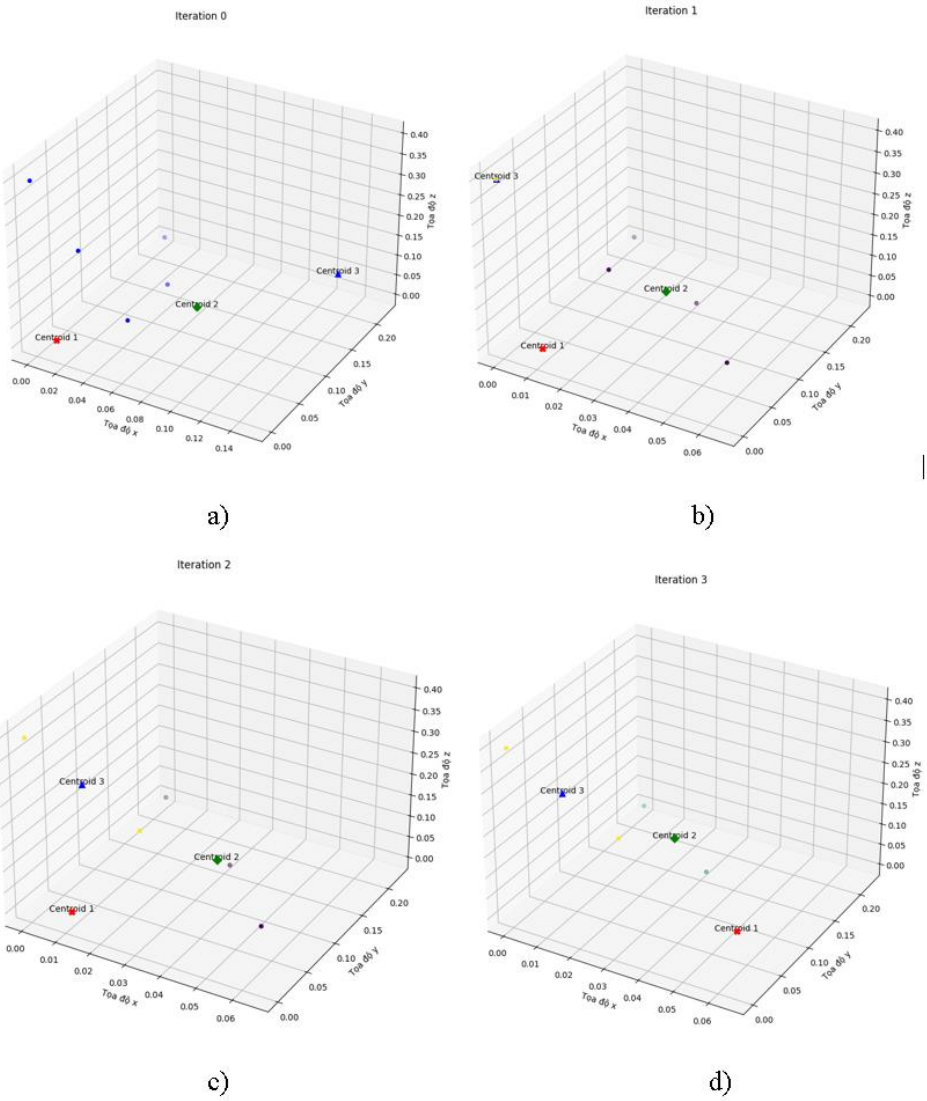
Giả sử tôi khởi tạo các trung tâm như sau:

$$m_1 = [0.01, 0.01, 0.01]$$

$$m_2 = [0.08, 0.08, 0.08]$$

$$m_3 = [0.15, 0.15, 0.15]$$

Kết quả trực quan sau khi thực hiện K-means ta thấy, thuật toán trải qua 3 lần lặp và 1 bước khởi tạo (*Hình 18*):



Hình 18. Trực quan hóa k-means với khởi tạo centroid khác

Lúc này, thuật toán dừng sau 3 lần lặp, trả về kết quả của các trung tâm như sau:

Centroid	Tọa độ
m_1	$[0.065,\ 0,\ 0.133]$
m_2	$[0.016,\ 0.185,\ 0]$
m_3	$[0.016,\ 0,\ 0.332]$

Bảng 13. Kết quả vị trí các centroid cuối cùng với cách khởi tạo centroid khác

Kết quả phân cụm sau khi k-means với centroid khởi tạo mới:

Bài báo (Articles/Documents)	Thuộc cluster có centroid là
1	m_1
2	m_3
3	m_3
4	m_2
5	m_2

Bảng 14. Kết quả phân cụm sau các khởi tạo centroid khác

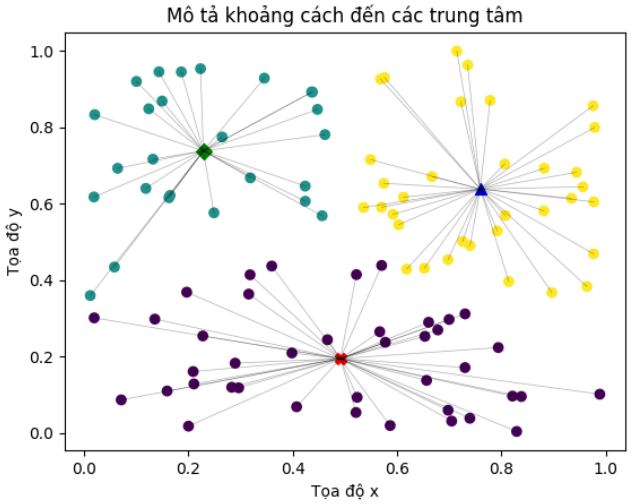
Vì sự khác nhau trong kết quả phân cụm trong việc thay đổi k hay khởi tạo centroids khác nhau, ta phải đánh giá kết quả phân cụm của bài báo để biết kết quả đó thực hiện ổn hay chưa. Một phương thức đánh giá là tính mức độ đồng nhất của một cluster (Cluster heterogeneity).

7.3.2 Phương thức đánh giá:

Mức độ đồng nhất của một cluster hay còn gọi là hàm sai số của bài toán K-means được tính bằng tổng tất cả tổng bình phương khoảng cách cách các điểm nằm trong một vùng phân cụm qua tất cả vùng phân cụm tìm được.

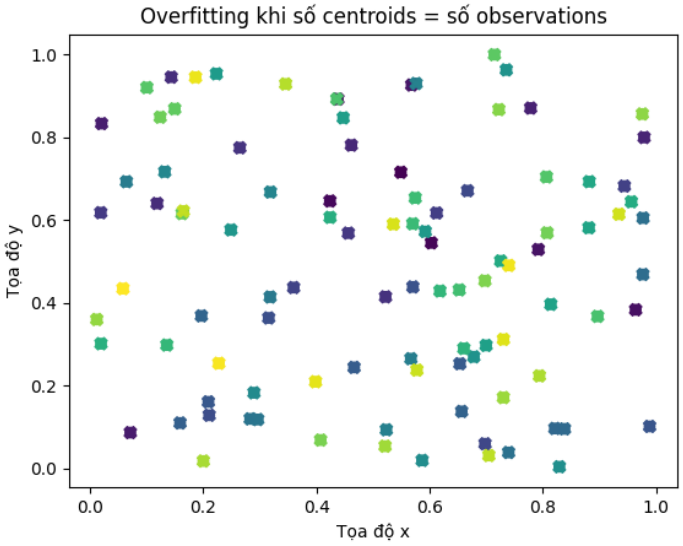
$$L = \sum_{j=1}^{k} \sum_{i:y_i=j} \|x_i - m_j\|_2^2$$

Heterogeneity chính là tổng bình phương tất cả khoảng cách của các điểm khảo sát đến centroid trung tâm gần nó nhất (*Hình 19* minh họa các đường khoảng cách)



Hình 19. Minh họa các khoảng cách đến centroid

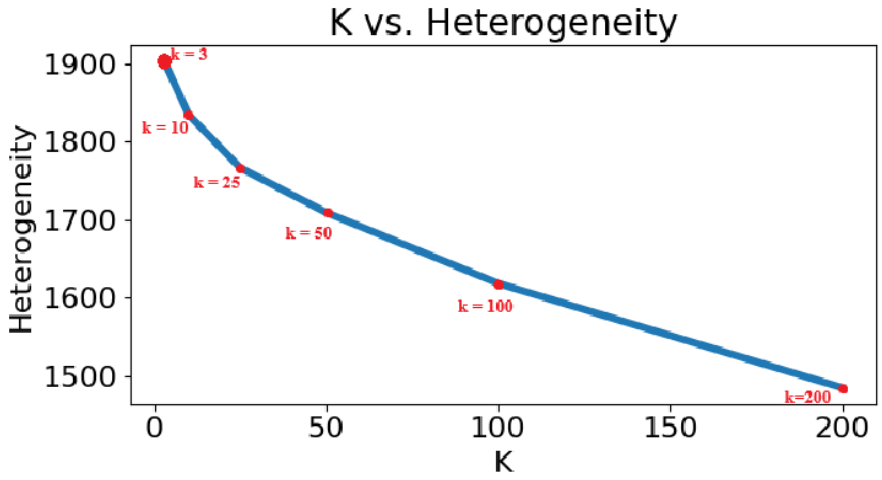
Khi tối ưu hóa thuật toán, hàm càng nhỏ kết quả càng tốt. Nhưng ta phải lưu ý với số điểm k càng cao thì hàm L càng thấp, đến một mức nào đó sẽ bị "quá khớp" (overfitting). Giả sử số k = với điểm khảo sát thì hàm L = 0 vì số trung tâm centroid đặt ra nằm ngay vào tất cả điểm khảo sát, và khoảng cách của trung tâm đến điểm khảo sát đó bình phương bằng 0. (*Hình 20* minh họa overfitting quá mức, khi số lượng trung tâm khởi tạo = số điểm khảo sát)



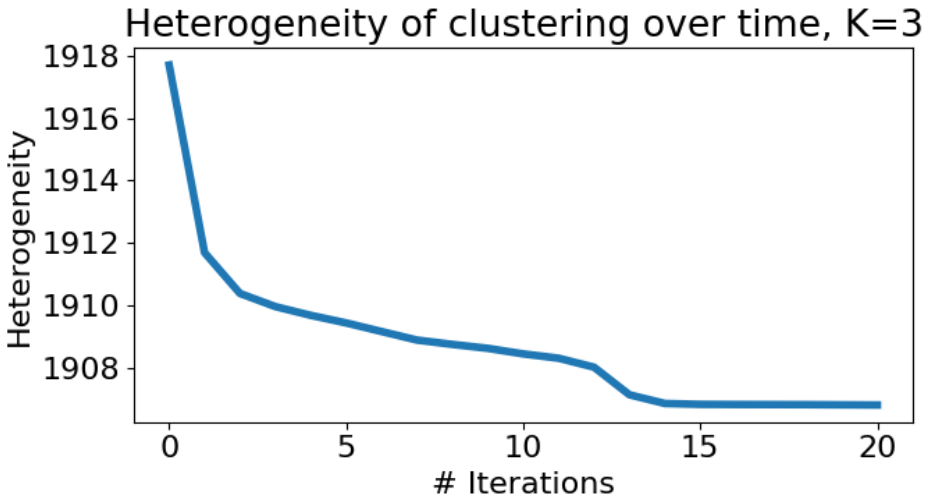
Hình 20. Overfitting dữ liệu mức cao nhất

Vấn đề tiếp theo là việc chọn số lần lặp (Iteration) cũng sẽ thay đổi hàm lost và giảm mức đồng nhất của các cụm dữ liệu.

Vậy để chọn k cho phù hợp với dữ liệu huấn luyện, ta nên tính toán Cluster heterogeneity qua các số k, vẽ biểu đồ rồi chọn số k cho phù hợp (*Hình 21*), cũng như vẽ biểu đồ cho số lần lặp so với mực đồng nhất của các cụm dữ liệu, rồi chọn số lần lặp cho phù hợp (*Hình 22*). Hình biểu thị mức đồng nhất qua số k khác nhau và Hình biểu thị mức đồng nhất qua số lần lặp khác nhau cho bộ dữ liệu báo mạng Việt Nam.



Hình 21. Heterogeneity so với số K



Hình 22. Heterogeneity so với số Iteration

Qua hai đồ thị, nếu muốn có kết quả phân cụm tốt với bộ dữ liệu báo mạng số k nằm từ 25 đến 50 vì sau điểm k = 50, độ dốc của mức heterogeneity không nhiều bằng từ 25 đến

50, một cách khác là ta đơn giản nhắm chừng *Hình 21* và sử dụng phương pháp "Elbow" để lấy số K.

7.3.3 Khởi tạo centroid tốt hơn với K-means++

Nếu như việc khởi tạo các centroid cho thuật toán là tất yếu, tôi sẽ sử dụng K-means++ để nâng cao hiệu suất hoạt động cho K-means, giúp K-means hội tụ tốt hơn.

Khởi tạo K-means++:

Bước 1: Chọn ngẫu nhiên điểm data khảo sát làm một centroid

Bước 2: Với mỗi điểm khảo sát x_i tiếp theo, tính khoảng cách từ x_i đến điểm centroid trung tâm gần nhất là $d(x_i)$

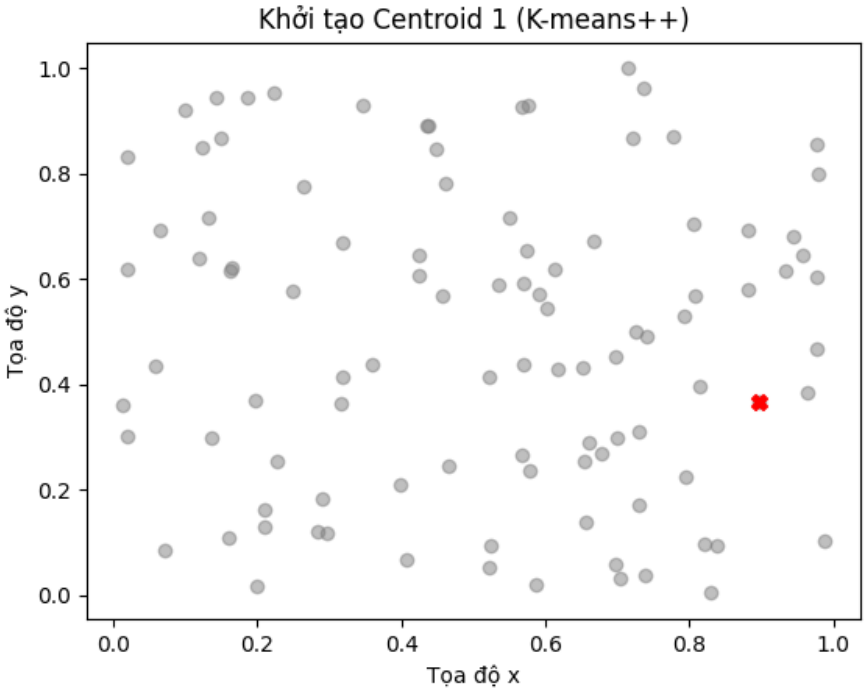
Bước 3: Chọn điểm khảo sát tiếp theo làm centroid với xác xuất chọn tỉ lệ thuận với $d(x_i)^2$

Bước 4: Lặp lại bước 2 đến khi chọn đủ số k.

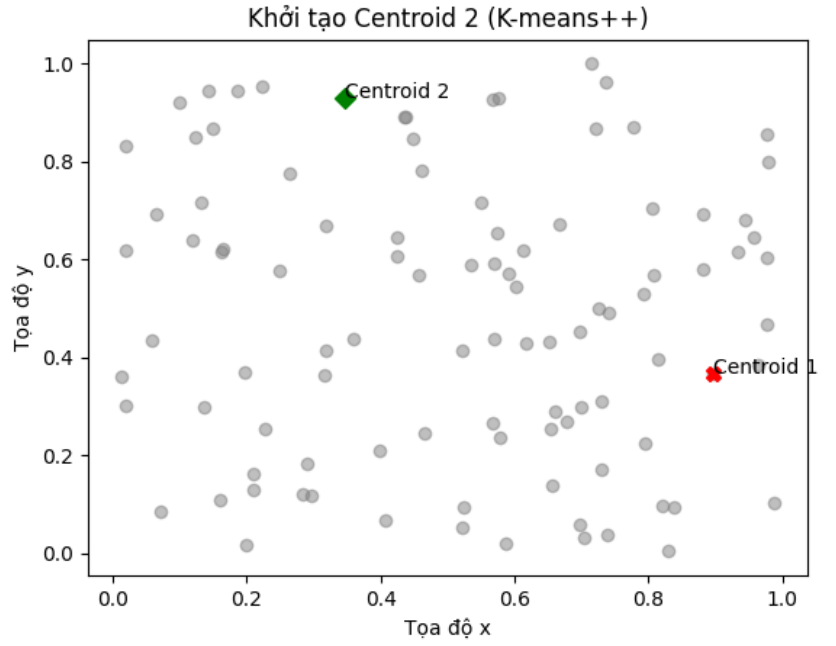
Ưu điểm: Thời gian hội tụ sẽ nhanh hơn do các centroid thường được phân bổ rải đều phụ thuộc vào dữ liệu dẫn đến thời gian chạy thấp hơn.

Nhược điểm: Tính toán phức tạp và đòi hỏi hơn là khởi tạo ngẫu nhiên.

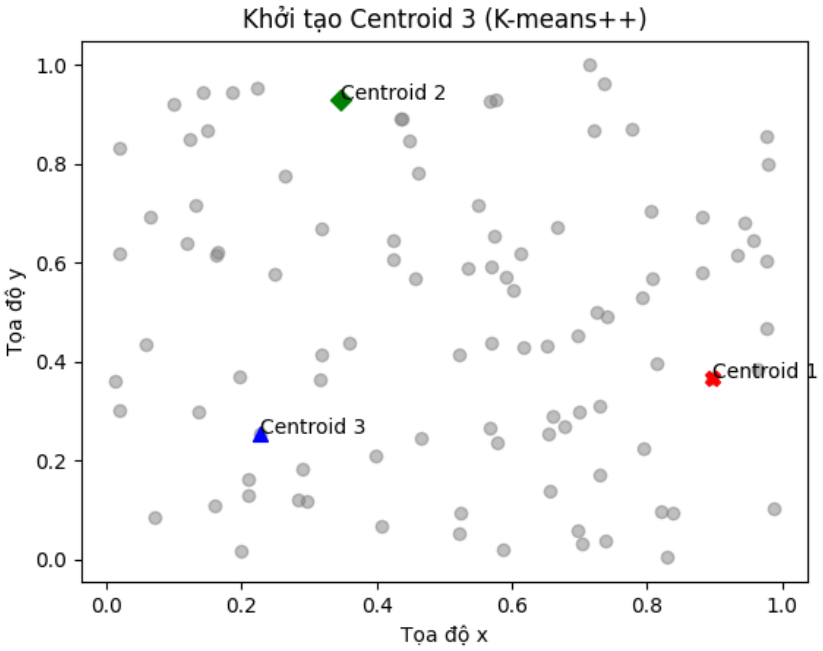
Hình minh họa cho K-means++ với k = 3 khởi tạo ba trung tâm centroid ngẫu nhiên (*Hình 23, Hình 24, Hình 25*):



Hình 23. Minh họa K-means++ bước 1



Hình 24. Minh họa K-means++ bước 2

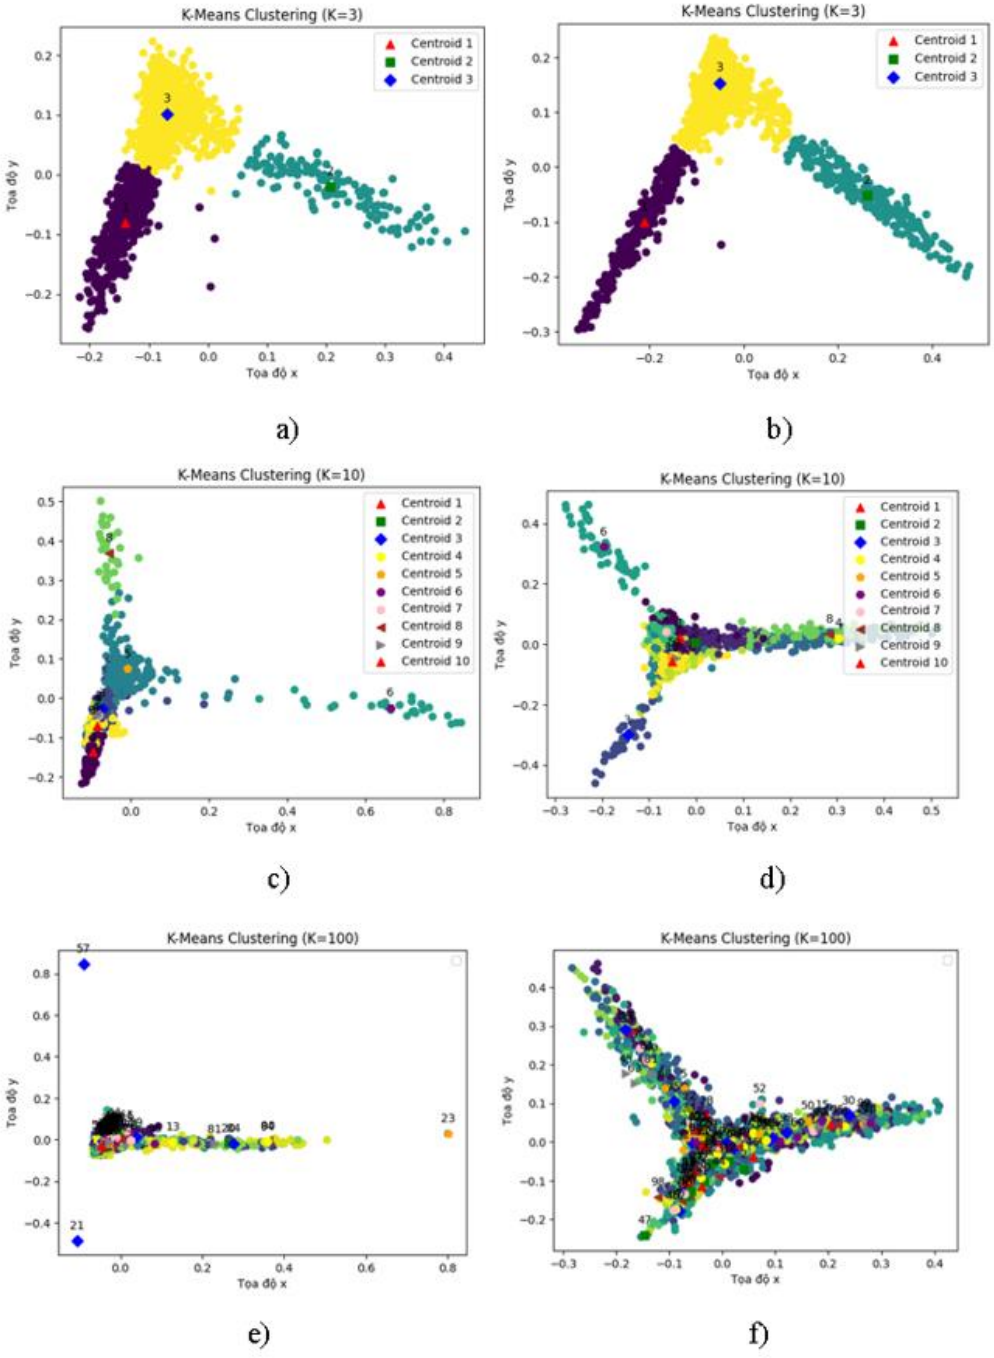


Hình 25. Minh họa K-means++ bước 3

7.4. Kết quả đạt được:

7.4.1 Kết quả phân cụm các bài báo.

Sau khi áp dụng thuật toán K-means vào phân cụm nhóm dataset1 và dataset2 gồm nhiều bài báo ngẫu nhiên, đây là kết tôi đạt được:



Hình 26. So sánh kết quả giữa 2 dataset trong ở dataset báo mạng Vietnam

Hình 26 thể hiện kết quả phân cụm khác nhau giữa 2 tệp dữ liệu dataset1 và dataset2 qua các số k khác nhau. Các hình bên trái (*Hình 26 a, c, e*) là kết quả K-means của dataset1 và (*Hình 26 b, d, f*) là kết quả K-means của dataset2.

Dữ liệu được nén xuống thành dữ liệu với 2 tọa độ x, y bằng phương thức PCA để vẽ thành đồ thị. Ta nhận thấy với k bằng 3, dữ liệu được tách thành 3 nhóm dữ liệu với 3 màu khác nhau. Dữ liệu màu tím sẽ thuộc cluster 1 do nằm gần tam giác, dữ liệu vàng sẽ thuộc và có nhãn là cluster 3 do nằm gần centroid hình thoi. Với một số K cao hơn, biểu diễn dữ liệu đa chiều dưới đồ thị 2 chiều sẽ khiễn dữ liệu bị nhòa và khó nhận xét. Để giữ cho báo cáo đồng nhất, tôi vẫn sẽ tiếp tục sử dụng k = 3.

Kết quả sau khi đánh giá mức Heterogeneity của các cụm cluster dưới các k khác nhau là:

Số k	Heterogeneity dataset1	Heterogeneity dataset2
3	1903.62529	1870.05599
10	1834.10863	1793.25158
100	1636.45003	1585.60916

Bảng 15. Bảng so sánh mức đồng nhất giữa 2 tệp dữ liệu qua các số k khác nhau

Ta có thể thấy với bộ dữ liệu dataset 2, mức Heterogeneity giảm xuống nhanh hơn vì bộ dữ liệu 2 tổng hợp số các bài báo cùng chủ đề nhiều hơn, giới hạn chủ đề cũng thấp hơn. Về tốc độ trong việc phân cụm, nếu ta nói chính xác về thuật toán K-means là tối ưu hóa tìm điểm hội tụ, thuật toán có độ phức tạp về thời gian là O(t*d*k*n) với k là số K, d là số chiều (số chữ trong từ điển), n là số điểm khảo sát và t là số lần lặp (Thường tầm 20-30 it sẽ hội tụ với bộ dataset của tôi). Còn nếu nói về thời gian tính toán trên máy chủ của tôi, thì trung bình khi train với k = 3 trong tập dữ liệu với 2000 dữ liệu theo tôi ghi nhận được nó sẽ train xong trong 3 giây, công việc query chỉ tốn 1 giây mỗi query.

7.4.2 Khám phá kết quả phân cụm

Xem xét các cụm dữ liệu trong dataset1:

```
==========================================================
Cluster 0
thi:0.046
u19:0.043
tôi:0.042
học:0.040
thí:0.039


* Tiền đạo Quốc Việt chụp ảnh cùng bố. Ảnh: FBNV     0.91755
  Phút 90 trận chung kết giải U21 quốc gia giữa NutiFood và CLB Hà Nội , tỷ số đang là 0-0.
  Một cái bóng áo

* Thể thao                                           0.92886
  Dù tạo ra nhiều cơ hội hơn nhưng U19 Indonesia bất lực trong việc ghi bàn, đành chấp nhận
  hòa 0-0 trước U19 Việt Nam.

* Thể thao                                           0.93003
  - Những bí quyết nào giúp ông thành công ở Việt Nam? - Đầu tiên tôi tôn trọng văn hóa và p
  hong tục của Việt

* Học Đường                                          0.93082
  Năm học 2022 - 2023 là năm học cả ba cấp đều áp dụng chương trình phổ thông mới. Bậc tiểu
  học và THCS tiếp

* Giáo dục                                           0.93098
  Ngày 24/7, sau khi công bố điểm thi tốt nghiệp THPT năm 2022 của một triệu thí sinh, trong
   đó hơn 859.500 em thi vừa

* XÃ HỘI                                             0.93142
  Theo đoàn số 1 do ông Trần Thanh Bình, Giám đốc Sở GD-ĐT TP Cần Thơ làm trưởng đoàn đến đi
  ểm thi tại Trường THPT

* Giáo dục                                           0.93230
  Trong chương trình tư vấn truyền hình trực tuyến "Sau khi biết kết quả thi, thí sinh cần l
  àm gì?" do Báo Thanh Niên tổ

* Thể thao                                           0.93265
  Thắng liền 4 trận, ghi 18 bàn ở vòng bảng Không thể nói tuyển nữ Việt Nam có sự chuẩn bị k
  ém chu đáo cho
```

Hình 27. Cluster 0 trong dataset1

Cụm dữ liệu thứ 0 chứa rất nhiều đề tài (Cluster 0 thể hiện ở *Hình* 27). Các chữ cái dưới tựa đềđược đánh giá quan trọng liên quan đến cụm như "thi", "học" liên quan đến giáo dục, "u19" liên quan đến thể thao và "tôi" liên quan đến các câu chuyện kể tự sự. Ngoài đề tài ra, các cụm dữ liệu còn thể hiện khoảng cách của bài báo mạng đó đến trung tâm centroid đang xét, như bài báo đầu tiên nói về bóng đá và có khoảng cách đến trung tâm gần nhất là 0.91755.

```
Cluster 1
nga:0.154
ukraine:0.109
dầu:0.082
quân:0.054
khí:0.045


* Thế giới                                              0.84753
  "Các đợt tập kích bằng vũ khí chính xác cao phóng từ mặt đất tiêu diệt một căn cứ của nhóm
   dân tộc chủ nghĩa

* THẾ GIỚI                                              0.86208
  Theo đó, phương Tây dù chuyển giao vũ khí hạng nặng và cung cấp thông tin tình báo cho Ukr
  aine nhưng không điều động quân

* Thế giới                                              0.86235
  Lời cảnh báo được đưa ra sau khi một quan chức Ukraine dự đoán rằng, các lực lượng vũ tran
  g nước này sẽ lấy lại

* Thế giới                                              0.86491
  Các cơ quan đặc vụ của Nga đã tăng cường hoạt động ở Đông Âu trong nỗ lực xác định và theo
   dõi các tuyến

* Thế giới                                              0.86894
  Điều phối viên truyền thông chiến lược của Hội đồng An ninh Quốc gia Mỹ John Kirby ngày 29
  /7 cho biết, Nhà Trắng không xem

* Thế giới                                              0.87067
  "Ukraine sử dụng pháo phản lực HIMARS do Mỹ sản xuất tập kích trung tâm giam giữ gần Yelen
  ovka, nơi giam các binh sĩ Ukraine,

*                                                       0.87084
  Hơn 4 tháng từ khi phát động "chiến dịch quân sự" ở Ukraine, Moscow đã điều chỉnh mục tiêu
  , tập trung hướng tới kiểm soát

*                                                       0.87355
  M142 HIMARS, Hệ thống Tên lửa Pháo binh Cơ động Cao do Mỹ cung cấp cho Ukraine, đã trở thà
  nh nguyên nhân khiến lực lượng
```

Hình 28. Cluster 1 trong dataset1

Cluster 1 (*Hình 28*) nhóm các bài liên quan đến các tin tức thế giới, đặc biệt liên quan đến mâu thuẫn giữa 2 quốc gia Nga và Ukraine

```
Cluster 2
bệnh:0.021
xe:0.018
an:0.016
tỉnh:0.014
ông:0.014


* Chính trị                                                0.93188
  Hội nghị và phiên họp được kết nối trực tuyến tới UBND các tỉnh, thành phố trực thuộc Trun
  g ương. Cùng tham dự Hội nghị

* Tin tức                                                 0.93573
  Tại phiên tòa sáng 21-7, HĐXX nhận định việc xác định tính chất, thương tích, mức độ tổn h
  ại sức khỏe bắt buộc phải trưng

* CHÍNH TRỊ                                               0.93883
  Dự buổi làm việc có Bộ trưởng, Chủ nhiệm Văn phòng Chính phủ Trần Văn Sơn; Bộ trưởng Bộ Cô
  ng Thương Nguyễn Hồng Diên; Bộ

* Thời sự                                                 0.93893
  Thành tựu của quan hệ Đối tác chiến lược Việt Nam - Anh Hai bên vui mừng nhận thấy, quan h
  ệ Đối tác chiến lược

*                                                         0.93964
  Như Dân Việt đã thông tin: Ông Nguyễn Văn Hơn (56 tuổi, ngụ ấp Nguyễn Rớt, xã Hậu Thạnh Đô
  ng, huyện Tân Thạnh, tỉnh Long

* CHÍNH TRỊ                                               0.94028
  Thủ tướng đánh giá cao kết quả hội đàm giữa hai Bộ Tư pháp, kết quả hợp tác về pháp luật v
  à tư pháp giữa

* Bạn đọc                                                 0.94134
  Cầu bộ hành là để giải quyết ùn tắc, tạo an toàn cho người đi bộ đồng thời kết hợp sử dụng
   giao thông công

* Cơ quan Cảnh sát điều tra thực hiện khám xét tại CDC Khánh Hòa. 0.94273
  Đặc biệt, trong các đối tượng bị khởi tố, có cựu Bộ trưởng Bộ Y tế Nguyễn Thanh Long; cựu
  Bộ trưởng Bộ Khoa học
```

Hình 29. Cluster 2 trong dataset1

Cluster còn lại (*Hình 29*) nhóm các bài báo liên quan đến tin tức thời sự chính trị tại Việt Nam.

Tương tự như vậy ta có thể theo dõi các cụm dữ liệu của bộ dữ liệu dataset2 (*Hình 30, 31, 32)*:

```
==========================================================
Cluster 0
nga:0.135
ukraine:0.116
quân:0.065
khí:0.048
chiến:0.045


* Thế giới                                              0.83583
  Để trả lời các câu hỏi trên, Thanh Niên đã phỏng vấn ông Dov S.Zakheim (cựu Thứ trưởng Bộ
  Quốc phòng Mỹ và hiện đang

* Thế giới                                              0.83804
  Các cố vấn của Tổng thống Joe Biden đã bắt đầu thảo luận riêng về cách thức và khả năng Tổ
  ng thống Ukraine Volodymyr Zelensky

* Thế giới                                              0.84909
  Trong bản tin cập nhật hoạt động ngày 25.7, Bộ Quốc phòng Nga tuyên bố họ đã đẩy lùi hai t
  àu đổ bộ của Ukraine

* Thế giới                                              0.85085
  "Quân đội Nga đang cố gắng củng cố các vị trí của họ tại các khu vực bị (Nga) kiểm soát ở
  miền Nam Ukraine,

* Thế giới                                              0.85392
  Giới chức Ukraine ngày 28.6 cho biết 2 tên lửa của Nga đã lao vào một trung tâm mua sắm ở
  thành phố Kremenchuk, miền

* Thế giới                                              0.85603
  Quân đội Ukraine đang nỗ lực lấy lại thành phố Kherson ở miền Nam nước này. Kherson là thà
  nh phố lớn đầu tiên của Ukraine

* Thế giới                                              0.85614
  Bộ Quốc phòng Nga ngày 15/7 tuyên bố tên lửa hành trình chính xác cao Kalibr phóng từ biển
   đã đánh trúng một công trình

* Thế giới                                              0.85659
  Ngày 24.7, tại cuộc họp báo ở Cairo, Ngoại trưởng Lavrov trấn an giới lãnh đạo Ai Cập rằng
   nước này sẽ giao đủ ngũ
```

Hình 30. Cluster 0 trong dataset2

```
Cluster 1
học:0.146
thi:0.119
thí:0.117
tuyển:0.106
sinh:0.102


* Giáo dục                                              0.79300
  Năm 2022, lần đầu tiên Trường đại học Bách khoa (Đại học Quốc gia TP.HCM) xét tuyển tổng h
  ợp bao gồm các tiêu chí về

* Giáo dục                                              0.79521
  Trường ĐH Sư phạm kỹ thuật TPHCM công bố điểm chuẩn ĐH chính quy cho 4 phương thức tuyển s
  inh đầu tiên (tuyển thẳng, ưu

* Giáo dục                                              0.80157
  Trường đại học Sư phạm Hà Nội công bố điểm sàn xét tuyển theo kết quả thi tốt nghiệp THPT
  là từ 16 - 21,5.

* Giáo dục                                              0.80376
  Ngày 17/7, trường Đại học Ngoại thương công bố kết quả xét tuyển sớm của ba phương thức, g
  ồm: xét học bạ bậc THPT nếu

* Giáo dục                                              0.80666
  Thí sinh đã đủ điều kiện trúng tuyển (trừ điều kiện tốt nghiệp THPT) phải tự đặt thứ tự ng
  uyện vọng 1 trên hệ thống

* Giáo dục                                              0.81169
  Trước khi có điểm thi tốt nghiệp, thí sinh đã có thể dựa trên đáp án để ước lượng điểm số
  của bản thân, tìm

* Giáo dục                                              0.81264
  Năm 2022, Đại học Khoa học Tự nhiên (Đại học Quốc gia Hà Nội) tuyển 1.650 chỉ tiêu bằng sá
  u phương thức, trong đó gần

* Giáo dục                                              0.82028
  Phương thức xét tuyển bằng kết quả kỳ thi đánh giá năng lực do ĐHQG TP HCM tổ chức được 81
   cơ sở giáo dục
```

Hình 31. Cluster 1 trong dataset2

```
Cluster 2
cô:0.019
an:0.019
anh:0.018
ông:0.017
huyện:0.016


* Pháp luật                                              0.92523
  Như Dân Việt đã thông tin: Chiều 13/7, Tòa án nhân dân Cấp cao tại Hà Nội đã tuyên án phúc
   thẩm sau khi xét

* Pháp luật                                              0.93760
  Án mạng kinh hoàng Vào 6h45' ngày 7/7/2015, Công an tỉnh Bình Phước nhận được tin báo của
  người dân về việc phát hiện 6

* Thế giới                                              0.94133
  Trao đổi với Zing, bà Patricia Faraldo Cabana - giáo sư luật hình sự tại Đại học A Coruña
  - cho biết việc một công

* Pháp luật                                              0.94324
  Mới đây, TAND Cấp cao tại Hà Nội mở hai phiên phúc thẩm, xem xét đơn kháng cáo của cựu Chủ
   tịch UBND TP Hà

* Pháp luật                                              0.94423
  Chiều 20/7, TAND huyện Đức Hòa, tỉnh Long An tiếp tục phiên tòa xét xử sơ thẩm đối với ông
   Lê Tùng Vân (90 tuổi)

* Pháp luật                                              0.94444
  Trước đó, vào sáng cùng ngày, các luật sư đề nghị tiếp tục hoãn phiên tòa, tuy nhiên sau k
  hi hội ý, hội đồng xét

* Pháp luật                                              0.94511
  Cần làm rõ hành vi do vô ý hay cố ý Xung quanh vụ việc đưa thông tin sai sự thật về việc t
  ỷ phú

* Thế giới                                              0.94527
  Ông Abe, 68 tuổi, bước chân vào chính trường quốc gia với vai trò nghị sĩ vào năm 1993 sau
   cái chết của cha ông,
```

Hình 32. Cluster 2 trong dataset2

Vì bộ dữ liệu chỉ chứa các bài báo thuộc về 4 chủ đề, nên khi thực hiện phân cụm với k = 3, một cụm dữ liệu sẽ chứ 2 chủ đề. Cụm đó là cụm Cluster 2 chứa các bài báo về Pháp luật và Thế giới.

Trong quá trình vận hành trong bộ dữ liệu sẵn có, ta có thể thêm dữ liệu mới vào xử lý theo các bước sau: chuẩn bị dữ liệu mới cho nó đồng nhất với bộ dữ liệu sẵn có, cập nhật là mô hình phân cụm, thực hiện gán dữ liệu mới đó một cụm train mới.

7.5. Kết luận và hướng phát triển

7.5.1. Kết luận:

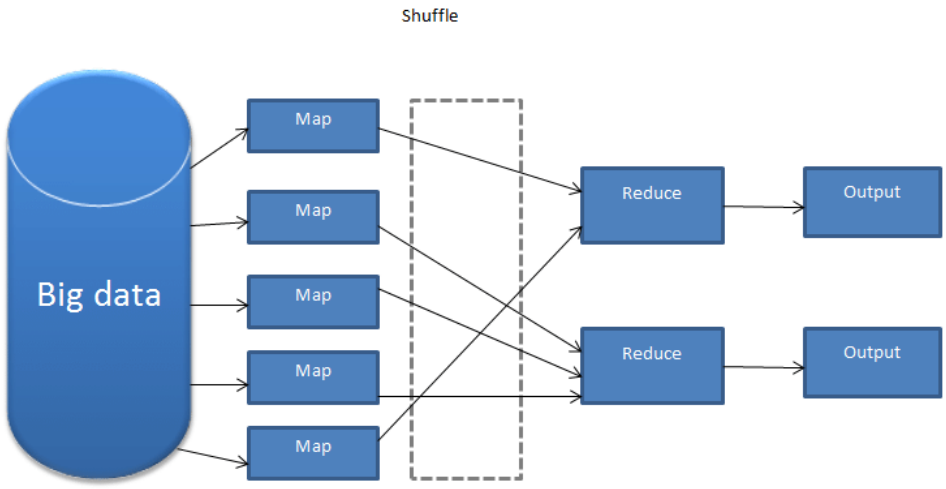
Thuật toán K-means không chỉ phân cụm bài báo mạng, K-means còn có thể phân cụm hình ảnh, hỗ trợ tăng hiệu quả cho các hệ thông search từ khóa trên mạng, phân cụm các tần số quét não bộ của con người để phân loại bệnh về não như bệnh động kinh. Ngoài ra ta còn có thể phân cụm các sản phẩm mua bán để nhóm nó lại giúp người dùng dễ tìm kiếm và chọn lựa dẫn đến tăng hiệu suất kinh tế cho doanh nghiệp bán hàng.

7.5.2. Hướng phát triển:

a) MapReduce và K-means

Trong các hệ thống dữ liệu lớn hadoop-hdsf, ta có thể lợi dụng tính toán song song để tính toán K-means cho dữ liệu lớn đó. Thuật toán K-means với phương thức bag_of _words có thể áp dụng framework MapReduce như sau:

Ta chia MapReduce thành 3 bước: Map, Shuffle và Reduce (*Hình 33*).



Hình 33. Mô hình Map Reduce [5]

Trong bước **Map**, ta xem đếm dữ liệu chữ trong toàn bộ documents, tạo cặp (key, value) như ('u19', 1);

```
map(document):
   for word in doc:
      print(word,1)
```

Trong bước **Reduce** lặp lại qua dữ liệu và trả vệ cặp key, value là một hàm tính toán.

```
reduce(word, value_lists):
   current_count = 0
   for i in value_list:
      current_count+= value_list[i]
   print(current_word, current_count)
```

Shuffle chỉ là xáo trộn dữ liệu giữa các máy song song

Ta có thể tối ưu Map Reduce hơn sử dụng Combiner, Combiner chỉ là cơ chế để báo cho các node máy trong hdfs thực hiện Reduce tại chính local máy đó trước khi đưa qua tính toán song song Reduce global.

Vậy để áp dụng thuật toán K-means vào Map Reduce, ta cũng phải chuyển đổi thuật toán K-means thành 2 bước chính: Map và Reduce.

Nếu ta xem bước 2 gán các điểm khảo sát vào một cluster gần nhất là bước map và bước 3 chỉnh lại centroid đến các trung tâm của các điểm khảo sát là Reduce, ta có thể vận dụng thuật toán như sau:

Map (Bước 2 trong K-means):
map($[m_1, m_2, \dots m_j], x_i$):

$y_i \leftarrow \text{argmin}_j \left\| x_i - m_j \right\|_2^2$

print(m_1, x_i)

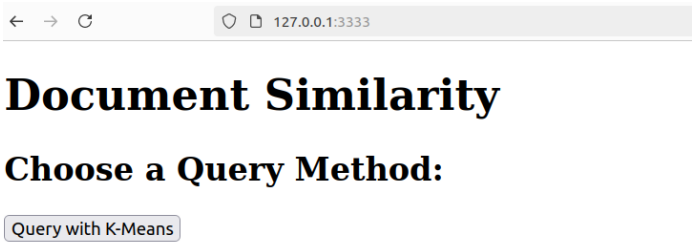
Reduce (Bước 3 trong K-means):
reduce(j, x_in_m : $[x_1, x_4 \dots]$):

```
   sum = 0
   current_count = 0
   for x in x_in_m:
      sum += x
      current_count += 1
   print(j, sum/current_count)
```

b) Xây dựng thành sản phẩm, phần mềm, website:

Tôi có xây dựng một website đơn giản sử dụng Python và Flask để demo vấn đề phân cụm và công dụng của nó. Giả sử doanh nghiệp muốn tổng hợp các thông tin hay đăng tin tức, ta có thể tăng mức hứng thú cho người dùng với K-means và cho họ đọc tiếp những bài báo liên quan. Website của tôi sẽ demo thử với số K = 3:

Đầu tiên đây là trang chủ của demo này (*Hình 34*), nếu muốn tôi có thể thiết kế thêm các thuật toán phân cụm khác vào trang web. Chọn "Query with K-Means", ta sẽ thực hiện công việc Query.



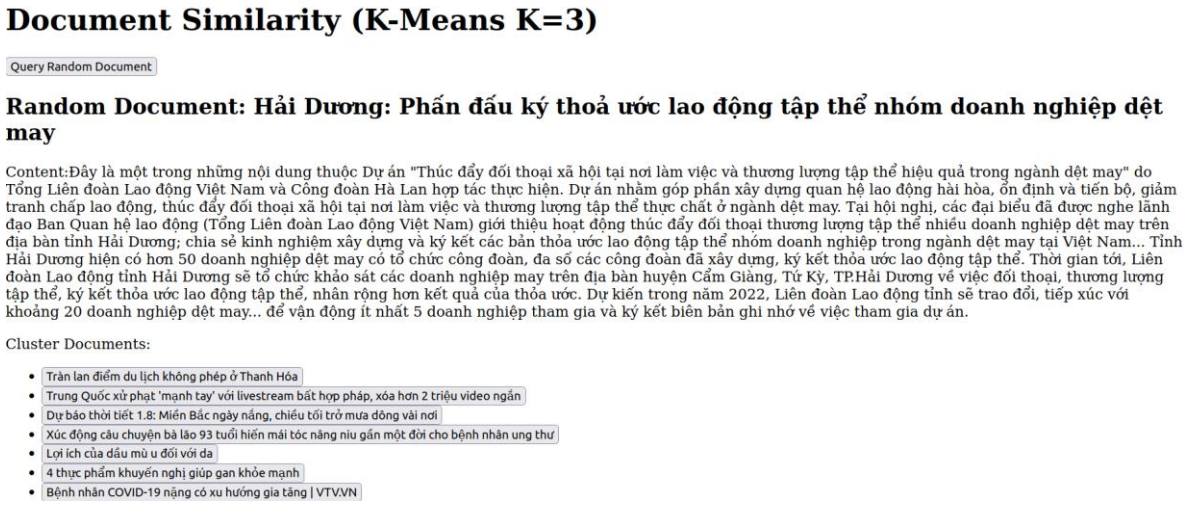
Hình 34. Trang chủ Index

Vì mục đích demo, tôi chỉ chọn ngẫu nhiên các bài báo bằng cách chọn nút Query Random Document (*Hình 35*).



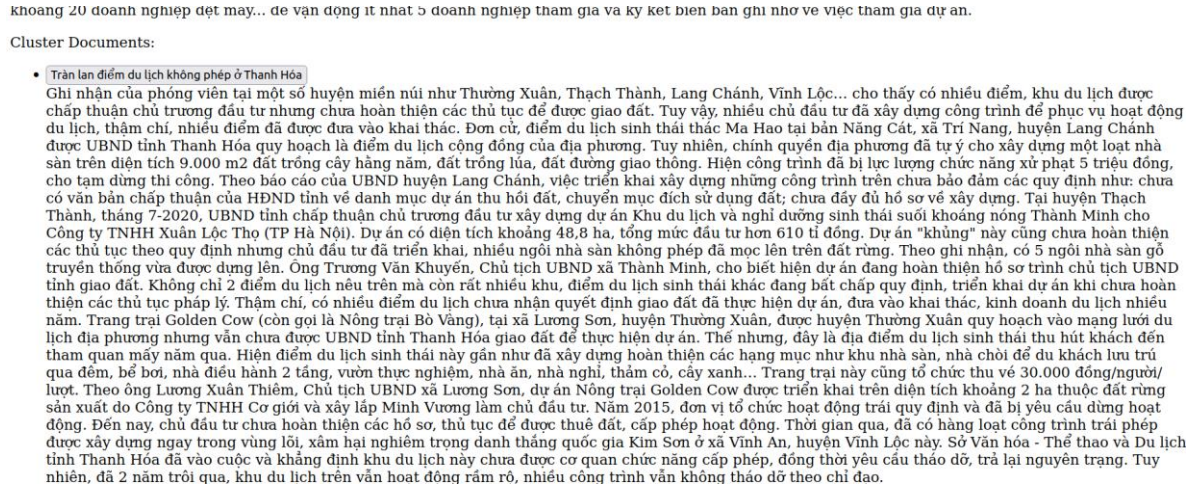
Hình 35. Trang K-means

Kết quả query (*Hình 36*).



Hình 36. Ví dụ bài báo ngẫu nhiên với K=3

Từ bài báo đang chọn , bên dưới bài báo hiện tại là các bài báo khác nằm trong cùng cụm với bài báo đang xét (*Hình 37 ví dụ 1 bài báo*).

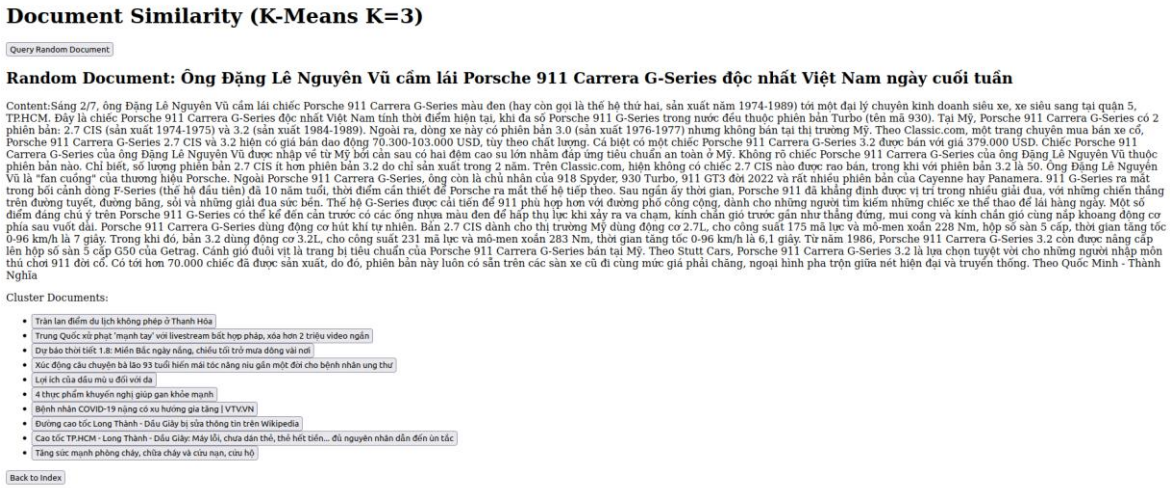


Hình 37. Mở rộng của một bài báo gần trung tâm cluster

Người dùng có thể chọn các bài báo đó và website sẽ đẩy người dùng đến trang web chứa bài báo đó. Trong trường hợp của tôi, tôi chỉ đơn giản là show ra luôn cái bài báo đó. Với K=3 tôi chỉ có 3 nhóm dữ liệu thôi, nên các bài báo sẽ đa dạng về thông tin với chủ đề.

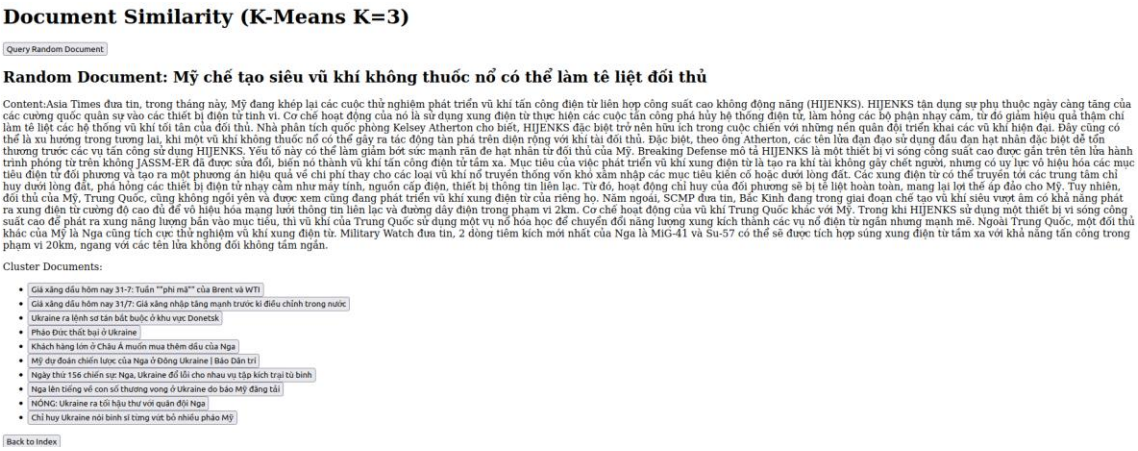
Một ví dụ bài báo khác (*Hình 38*):

Lúc này cluster của ta cũng thay đổi.



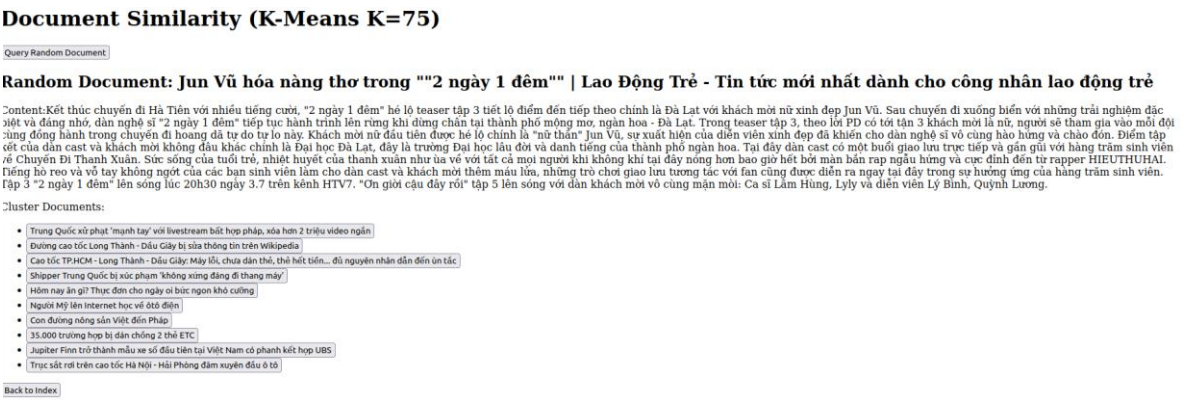
Hình 38. Thêm 1 ví dụ khác nằm trong cluster khác

Tiếp tục chọn ngẫu nhiên bài báo khác (*Hình 39*).



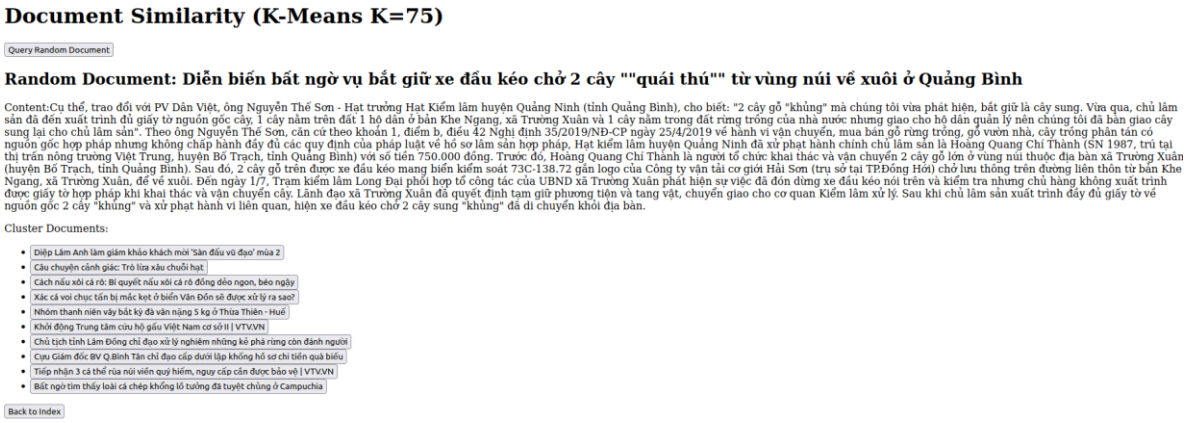
Hình 39. Ví dụ thêm

Thay đổi chỉ số K = 75 sẽ cho nhiều cluster hơn, nhưng chưa chắc đã đảm bảo về chủ đề. Chỉ những chủ đề gần trung tâm centroid mới giống nhau (*Hình 40*).



Hình 40. Ví dụ với K=75

Một ví dụ query khác với K = 75 (*Hình 41*).



Hình 41. Query khác với K=75

7.6. Mã nguồn, dữ liệu, giải thuật, đóng gói phần mềm:

7.6.1. Xử lý và demo thuật toán với Jupyter Notebook:

[1]:
```
import turicreate as tc
import numpy as np
import matplotlib.pyplot as plt
from scipy.sparse import csr_matrix

import json
import sys
import os
import random
import time

from sklearn.metrics.pairwise import pairwise_distances
from sklearn.preprocessing import OneHotEncoder, LabelEncoder
from sklearn.preprocessing import normalize

from copy import copy
from collections import defaultdict
from itertools import combinations
```

[2]:
```
json_data = tc.SFrame.read_json("news_dataset.json")
json_data
```

```
Parsing JSON records from /home/enderu/Downloads/ML-clustering/news_dataset.json
Successfully parsed 184539 elements from the JSON file /home/enderu/Downloads/ML-clustering/news_dataset.json
```

[2]:

author	content	crawled_at	id	picture_count	processed
	Chiều 31/7, Công an tỉnh Thừa Thiên - Huế đã có ...	2022-08-01 09:09:22.817308 ...	218270	3	0
(Nguồn: Sina)	Gần đây, Thứ trưởng Bộ Phát triển Kỹ thuật số, ...	2022-08-01 09:09:21.181469 ...	218269	1	0
Hồ Sỹ Anh	Kết quả thi tốt nghiệp THPT năm 2022 cho thấy ...	2022-08-01 09:09:15.311901 ...	218268	3	0
Ngọc Ánh	Thống đốc Kentucky Andy Beshear hôm 31/7 cho hay ...	2022-08-01 09:09:02.211498 ...	218267	1	0
HẢI YẾN - MINH LÝ	Vụ tai nạn giao thông liên hoàn trên phố đi bộ ...	2022-08-01 09:09:01.601170 ...	218266	12	0
	Chia sẻ trên Twitter, thị trưởng Hanover Belit ...	2022-08-01 09:09:01.320653 ...	218265	2	0
	"Em vỡ òa trong hạnh phúc khi được xướng tên ở ...	2022-08-01 09:08:57.167808 ...	218264	8	0
Hoàng Yến/VOV.VN		2022-08-01 09:08:51.092437 ...	218263	1	0
T.G	Soi kèo nhà cái Liverpool vs Strasbourg. Nhận đ ...	2022-08-01 09:08:47.355309 ...	218262	3	0
Đỗ Trung	Siêu sao Bồ Đào Nha được HLV Erik ten Hag bố trí ...	2022-08-01 09:08:42.496092 ...	218261	1	0

source	title	topic	url
docbao.vn	Tên cướp tiệm vàng tại Huế là đại uý công an, ...	Pháp luật	https://docbao.vn/phap-luat/ten-cuop-tiem-vang- ...
vtc.vn	Bỏ qua mạng 5G, Nga tiến thẳng từ 4G lên 6G ...	Sống kết nối	https://vtc.vn/bo-qua-mang-5g-nga-tien-than ...
thanhnien.vn	Địa phương nào đứng đầu cả nước tổng điểm 3 môn ...	Giáo dục	https://thanhnien.vn/dia-phuong-nao-dung-dau-ca- ...
vnexpress	Người chết trong mưa lũ 'nghìn năm có một' ở Mỹ ...	Thế giới	https://vnexpress.net/nguoi-chet-trong-mua-lu- ...
soha	Hải Phòng: Hình ảnh xe "điên" gây tai nạn liên ...	Thời sự - Xã hội	https://soha.vn/hai-phong-hinh-anh-xe-dien- ...
tuoitre.vn	Đức có thể suy thoái kinh tế năm nay ...	Thế giới	https://tuoitre.vn/duc-co-the-suy-thoai-kinh ...
baoquocte	Những khoảnh khắc đẹp của Gia Hân khi đăng quang ...	Giải trí	https://baoquocte.vn/nhung-khoanh-khac-dep-cua- ...
vov.vn	Lịch thi đấu vòng 11 V-League 2022: HAGL dễ ...	THỂ THAO	https://vov.vn/the-thao/lich-thi-dau-von ...
thethaovanhoa	Soi kèo nhà cái Liverpool vs Strasbourg. Nhận đ ...		https://thethaovanhoa.vn/du-doan-bong-da/soi-keo- ...
bongdaplus	Bị thay sau hiệp 1, Ronaldo đùng đùng bỏ về ...	Ngoại hạng Anh	https://bongdaplus.vn/ngoai-hang-anh/ronaldo-đ ...

```
[184539 rows x 10 columns]
Note: Only the head of the SFrame is printed.
You can use print_rows(num_rows=m, num_columns=n) to print more rows and columns.
```

Hình 42. Mã nguồn Notebook 1

```
[3]: clean_data = json_data.dropna()
sample_fraction = 3000 / len(clean_data)

dataset1 = clean_data.sample(sample_fraction, seed=0)
dataset1 = dataset1[dataset1['content'].apply(lambda x: x != None and str(x).strip() != '')]
dataset1 = dataset1[:2000]
```

```
[4]: [dataset1]
```

```
[4]: [Columns:
        author  str
        content str
        crawled_at      str
        id      int
        picture_count   int
        processed       int
        source  str
        title   str
        topic   str
        url     str

Rows: 2000


Data:
+--------------------------------+--------------------------------+
|              author            |             content            |
+--------------------------------+--------------------------------+
|     Bài và ảnh: Thanh Tuấn     | Ghi nhận của phóng viên tạ... |
|                                | Theo Thời báo Hoàn Cầu ngà... |
|              AN AN             | Dự báo thời tiết hôm nay 1... |
| Theo Ngọc Lâm (Tạp chí Du ...  |  PSG đối đầu với Nantes tr... |
|           Gia Khiêm            | Đầu tháng 7 vừa qua, người... |
|  DOÃN HẰNG (THEO STYLECRAZE)   | Chữa lành vết thương Dầu m... |
| Theo Trịnh Xuân nguyên (Th...  | Chuyên gia dinh dưỡng Vidh... |
| Quỳnh Anh-Chủ nhật, ngày 3...  | Tại cơ sở 2 Bệnh viện Bệnh... |
|          Lê Anh/VOV.VN         | Giao lộ thời gian số 3 với... |
|            Loan Chi            | Theo đó, bài viết về đường... |
+--------------------------------+--------------------------------+
+----------------------------+---------+---------------+-----------+--------------+
|         crawled_at         |   id    | picture_count | processed |    source    |
+----------------------------+---------+---------------+-----------+--------------+
| 2022-08-01 09:01:41.117687 | 218200 |       1       |     0     |     nld      |
| 2022-08-01 08:59:08.925317 | 218181 |       1       |     0     |  tuoitre.vn  |
| 2022-08-01 06:41:58.171137 | 217932 |       1       |     1     |   laodong    |
| 2022-08-01 06:24:58.269568 | 217907 |       2       |     1     |  24h.com.vn  |
| 2022-08-01 06:14:14.892803 | 217889 |       4       |     1     |   danviet    |
| 2022-08-01 02:54:34.263516 | 217640 |       1       |     1     |   laodong    |
| 2022-08-01 01:24:06.723143 | 217448 |       0       |     1     |  24h.com.vn  |
| 2022-08-01 01:15:42.518464 | 217424 |       0       |     1     |    vtv.vn    |
| 2022-07-31 23:36:56.301277 | 217143 |       5       |     1     |    vov.vn    |
| 2022-07-31 23:03:56.321618 | 217039 |       1       |     1     | thanhnien.vn |
+----------------------------+---------+---------------+-----------+--------------+
+--------------------------------+-----------------+
|              title             |      topic      |
+--------------------------------+-----------------+
| Tràn lan điểm du lịch khôn...  |   Du lịch xanh  |
| Trung Quốc xử phạt 'mạnh t...  |    Thế giới     |
| Dự báo thời tiết 1.8: Miền...  |                 |
| Video bóng đá PSG - Nantes...  |                 |
| Xúc động câu chuyện bà lão...  |    Đời sống     |
| Lợi ích của dầu mù u đối v...  |                 |
| 4 thực phẩm khuyến nghị gi...  |                 |
| Bệnh nhân COVID-19 nặng có...  |                 |
| Nhạc sĩ Đức Huy gây bất ng...  |     VĂN HÓA     |
| Đường cao tốc Long Thành -...  | Công nghệ - Game |
+--------------------------------+-----------------+
```

Hình 43. Mã nguồn Notebook 2

```
+------------------------------+
|              url             |
+------------------------------+
| https://nld.com.vn/du-lich... |
| https://tuoitre.vn/trung-q... |
| https://laodong.vn/moi-tru... |
| https://www.24h.com.vn/bon... |
| https://danviet.vn/xuc-don... |
| https://laodong.vn/lam-dep... |
| https://www.24h.com.vn/suc... |
| https://vtv.vn/xa-hoi/benh... |
| https://vov.vn/van-hoa/am-... |
| https://thanhnien.vn/duong... |
+------------------------------+
[2000 rows x 10 columns]
Note: Only the head of the SFrame is printed.
You can use print_rows(num_rows=m, num_columns=n) to print more rows and columns.]
```

```
[5]: dataset1['word_count'] = tc.text_analytics.count_words(dataset1['content'])
dataset1['tfidf'] = tc.text_analytics.tf_idf(dataset1['content'])
```

```
[6]: topics_of_choice = ['Pháp luật', 'Giáo dục', 'Thế giới', 'Giải trí']

dataset2 = clean_data[clean_data['topic'].apply(lambda x: x in topics_of_choice)]
sample_fraction = 3000/ len(dataset2)
dataset2 = dataset2.sample(sample_fraction)
dataset2 = dataset2[dataset2['content'].apply(lambda x: x != None and str(x).strip() != '')]
dataset2 = dataset2[:2000]
[dataset2]
```

```
[6]: [Columns:
        author  str
        content str
        crawled_at      str
        id      int
        picture_count   int
        processed       int
        source  str
        title   str
        topic   str
        url     str

 Rows: 2000

Data:
+------------------------------+------------------------------+
|             author           |            content           |
+------------------------------+------------------------------+
|                              | Chia sẻ trên Twitter, thí ... |
|          Ngô Minh Trí        | Thiếu tướng Christopher Mc... |
|           Bình Giang         | Ông Oleksiy Vadatursky, ng... |
|            Vi Trần           | Lãnh đạo Cơ quan Hàng khôn... |
|                              | Tối 31/7, Đoàn Thu Thủy đư... |
|           Phạm Công          | Chiều 31/7, ở Thừa Thiên H... |
|           Thạch Anh          | Không chỉ sở hữu nhan sác ... |
|          Hoàng Thuận         | Ngày 31/7, Công an quận Bì... |
| Phương Đăng (theo Barrons/... | Theo Barrons, Sergiy Bratc... |
| Minh Nhật (theo Times Of I... | "Không ai muốn cuộc chiến ... |
+------------------------------+------------------------------+
+----------------------------+---------+---------------+-----------+--------------+
|         crawled_at         |   id    | picture_count | processed |    source    |
+----------------------------+---------+---------------+-----------+--------------+
| 2022-08-01 09:09:01.320653 | 218265 |       2       |     0     |  tuoitre.vn  |
| 2022-08-01 08:24:54.645115 | 218092 |       3       |     1     | thanhnien.vn |
| 2022-08-01 08:17:11.611492 | 218080 |       1       |     1     |  tienphong   |
| 2022-08-01 07:44:16.811580 | 218024 |       1       |     1     | thanhnien.vn |
| 2022-08-01 07:25:37.989137 | 217997 |       1       |     1     |  docbao.vn   |
| 2022-08-01 03:42:39.813612 | 217717 |       0       |     1     |  vnexpress   |
| 2022-08-01 00:52:29.124458 | 217368 |       3       |     1     | thanhnien.vn |
| 2022-08-01 00:05:31.023019 | 217232 |       1       |     1     |    dantri    |
| 2022-08-01 00:05:29.106856 | 217231 |       1       |     1     |   danviet    |
| 2022-07-31 23:59:29.456820 | 217216 |       1       |     1     |   danviet    |
+----------------------------+---------+---------------+-----------+--------------+
+------------------------------+-----------+------------------------------+
|             title            |   topic   |              url             |
+------------------------------+-----------+------------------------------+
| Đức có thể suy thoái kinh ... |  Thế giới | https://tuoitre.vn/duc-co-... |
| Chiến lược của Mỹ ở Indo-P... |  Thế giới | https://thanhnien.vn/chien... |
| Ông trùm ngũ cốc Ukraine t... |  Thế giới | https://tienphong.vn/ong-t... |
| Washington chỉ trích Bắc K... |  Thế giới | https://thanhnien.vn/washi... |
| Hoa hậu Thể thao Thu Thủy ... |  Giải trí | https://docbao.vn/giai-tri... |
| 'Hối vàng' do tên cướp ném... | Pháp luật | https://vnexpress.net/hoi-... |
| Hoa hậu Kỳ Duyên diện biki... |  Giải trí | https://thanhnien.vn/hoa-h... |
| Đàm đàn em trọng thương rồ... | Pháp luật | https://dantri.com.vn/phap... |
| Giới chức Hải quân Ukraine... |  Thế giới | https://danviet.vn/gioi-ch... |
| Ngoại trưởng Ukraine tuyên... |  Thế giới | https://danviet.vn/ngoai-t... |
+------------------------------+-----------+------------------------------+
[2000 rows x 10 columns]
Note: Only the head of the SFrame is printed.
```

Hình 44. Mã nguồn Notebook 3

[7]:
```
dataset2['word_count'] = tc.text_analytics.count_words(dataset2['content'])
dataset2['tfidf'] = tc.text_analytics.tf_idf(dataset2['content'])
```

[8]:
```
def sframe_to_scipy_kmean(x, column_name):
    assert type(x[column_name][0]) == dict, \
        'Datatype not dict!'

    x = x.add_row_number('new_id')

    x = x.stack(column_name, ['feature', 'value'])

    unique_words = sorted(x['feature'].unique())
    mapping = {word:i for i, word in enumerate(unique_words)}
    x['feature_id'] = x['feature'].apply(lambda x: mapping[x])

    row_id = np.array(x['new_id'])
    col_id = np.array(x['feature_id'])
    data = np.array(x['value'])

    width = x['new_id'].max() + 1
    height = x['feature_id'].max() + 1

    mat = csr_matrix((data, (row_id, col_id)), shape=(width, height))
    return mat, mapping
```

[9]:
```
def assign_clusters(data, centroids):
    distances_from_centroids = pairwise_distances(data, centroids, metric='euclidean')
    cluster_assignment = np.argmin(distances_from_centroids, axis=1)
    return cluster_assignment
```

[11]:
```
def compute_heterogeneity(data, k, centroids, cluster_assignment):
    heterogeneity = 0.0
    for i in range(k):
        member_data_points = data[cluster_assignment==i, :]

        if member_data_points.shape[0] > 0:
            distances = pairwise_distances(member_data_points, [centroids[i]], metric='euclidean')
            squared_distances = distances**2
            heterogeneity += np.sum(squared_distances)

    return heterogeneity
```

[12]:
```
def smart_initialize(data, k, seed=None):
    if seed is not None:
        np.random.seed(seed)
    centroids = np.zeros((k, data.shape[1]))

    idx = np.random.randint(data.shape[0])
    centroids[0] = data[idx,:].toarray()
    squared_distances = pairwise_distances(data, centroids[0:1], metric='euclidean').flatten()**2

    for i in range(1, k):
        idx = np.random.choice(data.shape[0], 1, p=squared_distances/sum(squared_distances))
        centroids[i] = data[idx,:].toarray()

        squared_distances = np.min(pairwise_distances(data, centroids[0:i+1], metric='euclidean')**2,axis=1)

    return centroids
```

Hình 45. Mã nguồn Notebook 4

[13]:
```
def kmeans(data, k, initial_centroids, maxiter, record_heterogeneity=None, verbose=False):
    centroids = initial_centroids[:]
    prev_cluster_assignment = None

    for itr in range(maxiter):
        if verbose:
            print(itr)

        cluster_assignment = assign_clusters(data, centroids)
        centroids = revise_centroids(data, k, cluster_assignment)

        if prev_cluster_assignment is not None and \
          (prev_cluster_assignment==cluster_assignment).all():
            break

        if prev_cluster_assignment is not None:
            num_changed = np.sum(prev_cluster_assignment!=cluster_assignment)
            if verbose:
                print('    {0:5d} elements changed their cluster assignment.'.format(num_changed))

        if record_heterogeneity is not None:
            score = compute_heterogeneity(data, k, centroids, cluster_assignment)
            record_heterogeneity.append(score)

        prev_cluster_assignment = cluster_assignment[:]

    return centroids, cluster_assignment
```

[14]:
```
def get_initial_centroids(data, k, seed=None):
    if seed is not None:
        np.random.seed(seed)
    n = data.shape[0] # number of data points

    # Pick K indices from range [0, N).
    rand_indices = np.random.randint(0, n, k)

    centroids = data[rand_indices,:].toarray()

    return centroids
```

[15]:
```
def kmeans_multiple_runs(data, k, maxiter, num_runs, seed_list=None, verbose=False):
    heterogeneity = {}

    min_heterogeneity_achieved = float('inf')
    best_seed = None
    final_centroids = None
    final_cluster_assignment = None

    for i in range(num_runs):
        if seed_list is not None:
            seed = seed_list[i]
            np.random.seed(seed)
        else:
            seed = int(time.time())
            np.random.seed(seed)

        initial_centroids = smart_initialize(data, k, seed=seed)

        centroids, cluster_assignment = kmeans(data, k, initial_centroids, maxiter=400,
                                               record_heterogeneity=None, verbose=False)

        heterogeneity[seed] = compute_heterogeneity(data, k, centroids, cluster_assignment)

        if verbose:
            print('seed={0:06d}, heterogeneity={1:.5f}'.format(seed, heterogeneity[seed]))
            sys.stdout.flush()

        if heterogeneity[seed] < min_heterogeneity_achieved:
            min_heterogeneity_achieved = heterogeneity[seed]
            best_seed = seed
            final_centroids = centroids
            final_cluster_assignment = cluster_assignment

    return final_centroids, final_cluster_assignment
```

Hình 46. Mã nguồn Notebook 5

[16]:
```
def get_similar_docs_kmean(query_doc_id, centroids, cluster_assignment):
    id_to_index = {doc['id']: i for i, doc in enumerate(dataset1)}
    query_doc_index = id_to_index[query_doc_id]
    cluster_idx = cluster_assignment[k][query_doc_index]
    same_centroid_indices = [i for i, cluster in enumerate(cluster_assignment[k]) if cluster == cluster_idx]
    same_centroid_doc_ids = [list(id_to_index.keys())[list(id_to_index.values()).index(i)] for i in same_centroid_indices]
    similar_docs_sf = tc.SFrame({'id': same_centroid_doc_ids})
    similar_docs_sf = similar_docs_sf[similar_docs_sf['id'] != query_doc_id]
    similar_docs_sf = similar_docs_sf.head(10).join(dataset1[['id', 'topic', 'title', 'content']], on='id')
    return similar_docs_sf
```

[17]:
```
def visualize_document_clusters(dataset, tf_idf, centroids, cluster_assignment, k, map_word_to_index, display_content=True):
    map_index_to_word =  {v:k for k,v in map_word_to_index.items()}
    print('==========================================================')
    for c in range(k):
        print('Cluster {0:d}    '.format(c)),

        idx = centroids[c].argsort()[::-1]
        for i in range(5):
            print('{0:s}:{1:.3f}'.format(map_index_to_word[idx[i]], centroids[c][idx[i]])),
        print('')

        if display_content:
            distances = pairwise_distances(tf_idf, centroids[c].reshape(1, -1), metric='euclidean').flatten()
            distances[cluster_assignment!=c] = float('inf')

            nearest_neighbors = distances.argsort()

            for i in range(8):
                text = ' '.join(dataset[nearest_neighbors[i]]['content'].split(None, 25)[0:25])
                print('\n* {0:50s} {1:.5f}\n  {2:s}\n  {3:s}'.format(dataset[nearest_neighbors[i]]['topic'],
                    distances[nearest_neighbors[i]], text[:90], text[90:180] if len(text) > 90 else ''))
        print('==========================================================')
```

[26]:
```
import matplotlib.pyplot as plt
from sklearn.decomposition import PCA
import itertools

def plotting_kmeans(k, tf_idf, centroids, cluster_assignment):
    pca = PCA(n_components=2)
    reduced_centroids = pca.fit_transform(centroids[k])
    reduced_docs = pca.transform(tf_idf.toarray())

    markers = ['^', 's', 'D', 'o', 'p', 'H', '8', '<', '>']
    colors = ['red', 'green', 'blue', 'yellow', 'orange', 'purple', 'pink', 'brown', 'gray']
    plt.scatter(reduced_docs[:, 0], reduced_docs[:, 1], c=cluster_assignment[k], cmap='viridis')

    for i, centroid in enumerate(reduced_centroids):
        plt.scatter(centroid[0], centroid[1], marker=markers[i % len(markers)], s=50, c=colors[i % len(colors)])
        plt.annotate(f'{i+1}', (centroid[0], centroid[1]), textcoords="offset points", xytext=(0,10), ha='center')

    plt.title(f'K-Means Clustering (K={k})')
    plt.xlabel('Tọa độ x')
    plt.ylabel('Tọa độ y')
    plt.legend()
    plt.show()
```

*[18]:
```
tf_idf, map_index_to_word = sframe_to_scipy_kmean(dataset1, 'tfidf') #term frequency / inverse doc
tf_idf = normalize(tf_idf)
centroids = {}
cluster_assignment = {}
heterogeneity_values = []
k_list = [3, 10, 100]
seed_list = [0]
for k in k_list:
    heterogeneity = []
    centroids[k], cluster_assignment[k] = kmeans_multiple_runs(tf_idf, k, maxiter=400,
                                                               num_runs=len(seed_list), seed_list=seed_list,
                                                               verbose=True)
    score = compute_heterogeneity(tf_idf, k, centroids[k], cluster_assignment[k])
    heterogeneity_values.append(score)
```

```
seed=000000, heterogeneity=1903.62529
seed=000000, heterogeneity=1834.10863
seed=000000, heterogeneity=1636.45003
```

Hình 47. Mã nguồn Notebook 6

```
[54]: visualize_document_clusters(dataset1, tf_idf, centroids[3], cluster_assignment[3], 3, map_index_to_word, display_content=True)

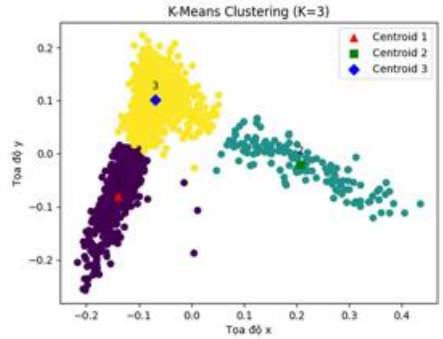
============================================================
Cluster 0
thi:0.046
u19:0.043
tôi:0.042
học:0.040
thí:0.039


* Tiến đạo Quốc Việt chụp ảnh cùng bó. Ảnh: FBNV     0.91755
  Phút 90 trận chung kết giải U21 quốc gia giữa NutiFood và CLB Hà Nội , tỷ số đang là 0-0.
  Một cái bóng áo

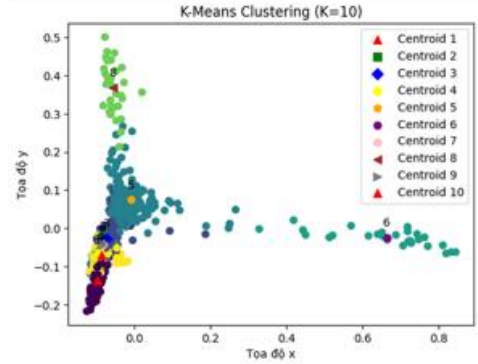
* Thể thao                                          0.92886
  Dù tạo ra nhiều cơ hội hơn nhưng U19 Indonesia bất lực trong việc ghi bàn, đành chấp nhận
  hòa 0-0 trước U19 Việt Nam.

* Thể thao                                          0.93003

[48]: plotting_kmeans(3, tf_idf, centroids, cluster_assignment)
```

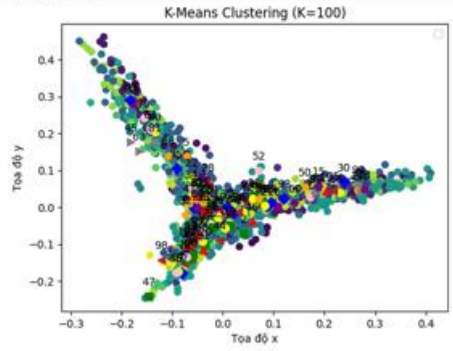



```
[49]: plotting_kmeans(10, tf_idf, centroids, cluster_assignment)
```




```
[27]: plotting_kmeans(100, tf_idf, centroids, cluster_assignment)

No artists with labels found to put in legend.  Note that artists whose label start with an underscore are ignored when legend() is called wi
th no argument.
```

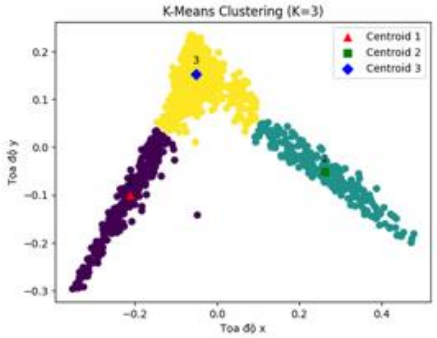


Hình 48. Mã nguồn Notebook 7

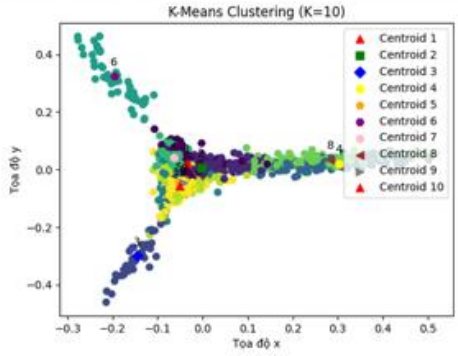
```
[22]: tf_idf, map_index_to_word = sframe_to_scipy_kmean(dataset2, 'tfidf')
tf_idf = normalize(tf_idf)
centroids = {}
cluster_assignment = {}
heterogeneity_values = []
#k_list = [2, 10, 25, 50, 100]
k_list = [3, 10, 100]
seed_list = [0]
#seed_list = [0, 20000, 40000, 60000, 80000, 100000, 120000]
for k in k_list:
    heterogeneity = []
    centroids[k], cluster_assignment[k] = kmeans_multiple_runs(tf_idf, k, maxiter=400,
                                                               num_runs=len(seed_list), seed_list=seed_list,
                                                               verbose=True)
    score = compute_heterogeneity(tf_idf, k, centroids[k], cluster_assignment[k])
    heterogeneity_values.append(score)
```

```
seed=000000, heterogeneity=1870.05599
seed=000000, heterogeneity=1793.25158
seed=000000, heterogeneity=1585.60916
```

```
[51]: plotting_kmeans(3, tf_idf, centroids, cluster_assignment)
```

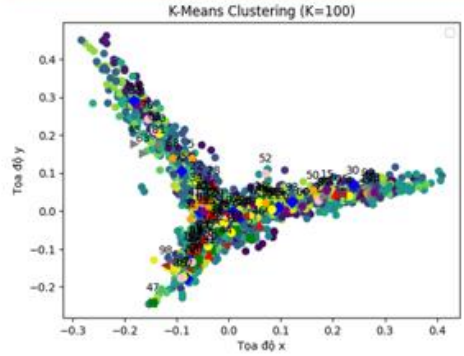



```
[52]: plotting_kmeans(10, tf_idf, centroids, cluster_assignment)
```




```
[28]: plotting_kmeans(100, tf_idf, centroids, cluster_assignment)
```

```
No artists with labels found to put in legend.  Note that artists whose label start with an underscore are ignored when legend() is called wi
th no argument.
```



Hình 49. Mã nguồn Notebook 8

```
[56]: visualize_document_clusters(dataset2, tf_idf, centroids[3], cluster_assignment[3], 3, map_index_to_word, display_content=True)
```

```
==========================================================
Cluster 0
nga:0.135
ukraine:0.116
quân:0.065
khí:0.048
chiến:0.045


* Thế giới                                          0.83583
  Để trả lời các câu hỏi trên, Thanh Niên đã phỏng vấn ông Dov S.Zakheim (cựu Thứ trưởng Bộ
  Quốc phòng Mỹ và hiện đang

* Thế giới                                          0.83804
  Các cố vấn của Tổng thống Joe Biden đã bắt đầu thảo luận riêng về cách thức và khả năng Tổ
  ng thống Ukraine Volodymyr Zelensky

* Thế giới                                          0.84909
```

```
[68]: def plot_heterogeneity(heterogeneity, k):
          plt.figure(figsize=(7,4))
          plt.plot(heterogeneity, linewidth=4)
          plt.xlabel('# Iterations')
          plt.ylabel('Heterogeneity')
          plt.title('Heterogeneity of clustering over time, K={0:d}'.format(k))
          plt.rcParams.update({'font.size': 16})
          plt.tight_layout()
```

```
[71]: %%time
      import numpy as np

      def plot_k_vs_heterogeneity(k_values, heterogeneity_values):
          plt.figure(figsize=(7,4))
          plt.plot(k_values, heterogeneity_values, linewidth=4)
          plt.xlabel('K')
          plt.ylabel('Heterogeneity')
          plt.title('K vs. Heterogeneity')
          plt.rcParams.update({'font.size': 16})
          plt.tight_layout()


      tf_idf, map_index_to_word = sframe_to_scipy_kmean(dataset1, 'tfidf') #term frequency / inverse doc
      tf_idf = normalize(tf_idf)
      centroids = {}
      cluster_assignment = {}
      heterogeneity_values = []
      k_list = [3, 10, 25, 50, 100, 200]
      seed_list = [0, 20000, 40000, 60000, 80000, 100000, 120000]

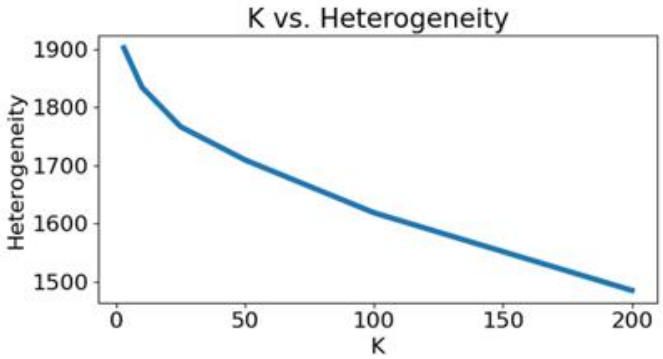
      for k in k_list:
          heterogeneity = []
          centroids[k], cluster_assignment[k] = kmeans_multiple_runs(tf_idf, k, maxiter=400,
                                                                     num_runs=len(seed_list),
                                                                     verbose=True)
          score = compute_heterogeneity(tf_idf, k, centroids[k], cluster_assignment[k])
          heterogeneity_values.append(score)
```

```
seed=000000, heterogeneity=1903.62529
seed=020000, heterogeneity=1904.39371
seed=040000, heterogeneity=1903.09180
seed=060000, heterogeneity=1901.70079
seed=080000, heterogeneity=1908.97909
seed=100000, heterogeneity=1906.41214
seed=120000, heterogeneity=1903.42697
seed=000000, heterogeneity=1834.10863
seed=020000, heterogeneity=1842.96667
seed=040000, heterogeneity=1842.03064
seed=060000, heterogeneity=1849.75074
seed=080000, heterogeneity=1847.26617
```

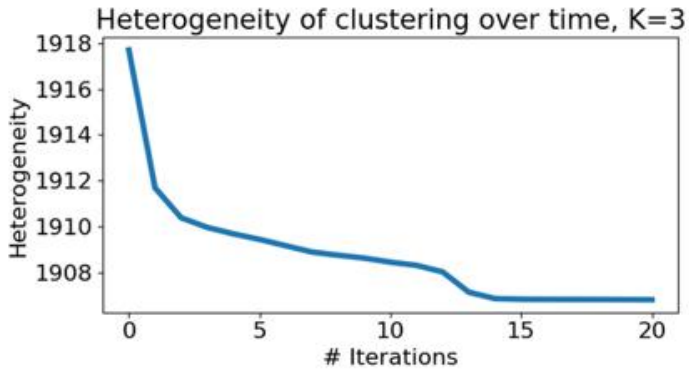
Hình 50. Mã nguồn Notebook 9

```
seed=100000, heterogeneity=1841.25090
seed=120000, heterogeneity=1842.70306
seed=000000, heterogeneity=1771.33131
seed=020000, heterogeneity=1781.53965
seed=040000, heterogeneity=1774.07175
seed=060000, heterogeneity=1766.24577
seed=080000, heterogeneity=1795.38472
seed=100000, heterogeneity=1776.84152
seed=120000, heterogeneity=1771.32902
seed=000000, heterogeneity=1719.08795
seed=020000, heterogeneity=1715.39878
seed=040000, heterogeneity=1716.21098
seed=060000, heterogeneity=1711.80387
seed=080000, heterogeneity=1722.39310
seed=100000, heterogeneity=1712.38085
seed=120000, heterogeneity=1709.19058
seed=000000, heterogeneity=1636.45003
seed=020000, heterogeneity=1627.24867
seed=040000, heterogeneity=1632.91379
seed=060000, heterogeneity=1627.63166
seed=080000, heterogeneity=1637.91132
seed=100000, heterogeneity=1618.43936
seed=120000, heterogeneity=1624.35318
seed=000000, heterogeneity=1493.62724
seed=020000, heterogeneity=1489.87385
seed=040000, heterogeneity=1486.54753
seed=060000, heterogeneity=1491.53231
seed=080000, heterogeneity=1493.81573
seed=100000, heterogeneity=1485.04835
seed=120000, heterogeneity=1496.85390
CPU times: user 2min 48s, sys: 15.8 s, total: 3min 3s
Wall time: 2min 47s
```

[72]:
```
plot_k_vs_heterogeneity(k_list, heterogeneity_values)
```



[76]:
```
k = 3
heterogeneity = []
initial_centroids = get_initial_centroids(tf_idf, k, seed=0)
centroids, cluster_assignment = kmeans(tf_idf, k, initial_centroids, maxiter=400,
                                       record_heterogeneity=heterogeneity, verbose=True)
plot_heterogeneity(heterogeneity, k)
```



Hình 51. Mã nguồn Notebook 10

7.6.2. Demo trên Python Flask:

a) File Python:

```
from flask import Flask, render_template, request, redirect, url_for
import turicreate as tc
import numpy as np
import matplotlib.pyplot as plt
from scipy.sparse import csr_matrix

import json
import sys
import os
import random
import time

from sklearn.metrics.pairwise import pairwise_distances
from sklearn.preprocessing import OneHotEncoder, LabelEncoder
from sklearn.preprocessing import normalize

from copy import copy
from collections import defaultdict
from itertools import combinations

app = Flask(__name__)

def sarray_to_json(x):
    return json.loads(x['tfidf'])


def sframe_to_scipy_kmean(x, column_name):
    assert type(x[column_name][0]) == dict, \
        'Datatype not dict!'

    x = x.add_row_number('new_id')

    x = x.stack(column_name, ['feature', 'value'])

    unique_words = sorted(x['feature'].unique())
    mapping = {word:i for i, word in enumerate(unique_words)}
    x['feature_id'] = x['feature'].apply(lambda x: mapping[x])

    row_id = np.array(x['new_id'])
    col_id = np.array(x['feature_id'])
    data = np.array(x['value'])

    width = x['new_id'].max() + 1
    height = x['feature_id'].max() + 1

    mat = csr_matrix((data, (row_id, col_id)), shape=(width, height))
    return mat, mapping
```

Hình 52. Mã nguồn Python Flask 1

```
def assign_clusters(data, centroids):
    distances_from_centroids = pairwise_distances(data, centroids, metric='euclidean')
    cluster_assignment = np.argmin(distances_from_centroids, axis=1)
    return cluster_assignment

def revise_centroids(data, k, cluster_assignment):
    new_centroids = []
    for i in range(k):
        member_data_points = data[cluster_assignment==i]
        centroid = member_data_points.mean(axis=0)
        centroid = centroid.A1
        new_centroids.append(centroid)
    new_centroids = np.array(new_centroids)

    return new_centroids

def compute_heterogeneity(data, k, centroids, cluster_assignment):
    heterogeneity = 0.0
    for i in range(k):
        member_data_points = data[cluster_assignment==i, :]

        if member_data_points.shape[0] > 0:
            distances = pairwise_distances(member_data_points, [centroids[i]], metric='euclidean')
            squared_distances = distances**2
            heterogeneity += np.sum(squared_distances)

    return heterogeneity

def smart_initialize(data, k, seed=None):
    if seed is not None:
        np.random.seed(seed)
    centroids = np.zeros((k, data.shape[1]))

    idx = np.random.randint(data.shape[0])
    centroids[0] = data[idx,:].toarray()
    squared_distances = pairwise_distances(data, centroids[0:1], metric='euclidean').flatten()**2

    for i in range(1, k):
        idx = np.random.choice(data.shape[0], 1, p=squared_distances/sum(squared_distances))
        centroids[i] = data[idx,:].toarray()

        squared_distances = np.min(pairwise_distances(data, centroids[0:i+1], metric='euclidean')**2,axis=1)

    return centroids
```

Hình 53. Mã nguồn Python Flask 2

```
def kmeans(data, k, initial_centroids, maxiter, record_heterogeneity=None, verbose=False):
    centroids = initial_centroids[:]
    prev_cluster_assignment = None

    for itr in range(maxiter):
        if verbose:
            print(itr)

        cluster_assignment = assign_clusters(data, centroids)
        centroids = revise_centroids(data, k, cluster_assignment)

        if prev_cluster_assignment is not None and \
          (prev_cluster_assignment==cluster_assignment).all():
            break

        if prev_cluster_assignment is not None:
            num_changed = np.sum(prev_cluster_assignment!=cluster_assignment)
            if verbose:
                print('    {0:5d} elements changed their cluster assignment.'.format(num_changed))

        if record_heterogeneity is not None:
            score = compute_heterogeneity(data, k, centroids, cluster_assignment)
            record_heterogeneity.append(score)

        prev_cluster_assignment = cluster_assignment[:]

    return centroids, cluster_assignment

def get_initial_centroids(data, k, seed=None):
    if seed is not None:
        np.random.seed(seed)
    n = data.shape[0] # number of data points

    # Pick K indices from range [0, N).
    rand_indices = np.random.randint(0, n, k)

    centroids = data[rand_indices,:].toarray()

    return centroids

def kmeans_multiple_runs(data, k, maxiter, num_runs, seed_list=None, verbose=False):
    heterogeneity = {}

    min_heterogeneity_achieved = float('inf')
    best_seed = None
    final_centroids = None
    final_cluster_assignment = None

    for i in range(num_runs):
        if seed_list is not None:
            seed = seed_list[i]
            np.random.seed(seed)
        else:
            seed = int(time.time())
            np.random.seed(seed)

        initial_centroids = smart_initialize(data, k, seed=seed)

        centroids, cluster_assignment = kmeans(data, k, initial_centroids, maxiter=400,
                                               record_heterogeneity=None, verbose=False)

        heterogeneity[seed] = compute_heterogeneity(data, k, centroids, cluster_assignment)

        if verbose:

            print('seed={0:06d}, heterogeneity={1:.5f}'.format(seed, heterogeneity[seed]))
            sys.stdout.flush()

        if heterogeneity[seed] < min_heterogeneity_achieved:
            min_heterogeneity_achieved = heterogeneity[seed]
            best_seed = seed
            final_centroids = centroids
            final_cluster_assignment = cluster_assignment

    return final_centroids, final_cluster_assignment
```

Hình 54. Mã nguồn Python Flask 3

```
def get_similar_docs_kmean(query_doc_id, centroids, cluster_assignment):
    id_to_index = {doc['id']: i for i, doc in enumerate(dataset1)}
    query_doc_index = id_to_index[query_doc_id]
    cluster_idx = cluster_assignment[k][query_doc_index]
    same_centroid_indices = [i for i, cluster in enumerate(cluster_assignment[k]) if cluster == cluster_idx]
    same_centroid_doc_ids = [list(id_to_index.keys())[list(id_to_index.values()).index(i)] for i in same_centroid_indices]
    similar_docs_sf = tc.SFrame({'id': same_centroid_doc_ids})
    similar_docs_sf = similar_docs_sf[similar_docs_sf['id'] != query_doc_id]
    similar_docs_sf = similar_docs_sf.head(10).join(dataset1[['id', 'topic', 'title', 'content']], on='id')
    return similar_docs_sf

@app.route('/')
def index():
    return render_template('index.html')

@app.route('/home_kmean')
def home_kmeans():
    return render_template('home_kmean.html', k_list=k_list)

app.route('/query_cluster_kmeans', methods=['POST'])
def query_cluster_kmeans():
    k = int(request.form['cluster'])
    centroid = centroids[k]
    distances = pairwise_distances(tf_idf, centroid, metric='euclidean')
    closest_docs = np.argsort(distances.flatten())[:10]
    closest_docs_list = closest_docs.tolist()
    closest_docs_sf = dataset1[dataset1['id'].apply(lambda x: x in closest_docs_list)]
    return render_template('cluster_docs.html', closest_docs=closest_docs_sf, k=k)

def get_random_index():
    random_val = random.randint(0, 2000)
    return dataset1['id'][random_val]

#init
dataset1 = tc.SFrame.read_csv("dataset1.csv")
dataset1['tfidf'] = dataset1.apply(sarray_to_json)
random_index = get_random_index()

#init_Kmean
tf_idf, map_index_to_word = sframe_to_scipy_kmean(dataset1, 'tfidf')
tf_idf = normalize(tf_idf)
centroids = {}
cluster_assignment = {}
heterogeneity_values = []
#k_list = [2, 10, 25, 50, 100]
k_list = [3]
seed_list = [0]
#seed_list = [0, 20000, 40000, 60000, 80000, 100000, 120000]
for k in k_list:
    heterogeneity = []
    centroids[k], cluster_assignment[k] = kmeans_multiple_runs(tf_idf, k, maxiter=400,
                                                               num_runs=len(seed_list), seed_list=seed_list,
                                                               verbose=True)
    score = compute_heterogeneity(tf_idf, k, centroids[k], cluster_assignment[k])
    heterogeneity_values.append(score)

if __name__ == '__main__':
    app.run(debug=True, port=3333)
```

Hình 55. Mã nguồn Python Flask 4

b) File index.html nằm trong thư mục templates cho Flask:

```html
<!DOCTYPE html>
<html>
  <head>
    <title>Document Similarity</title>
  </head>
  <body>
    <h1>Document Similarity</h1>
    <h2>Choose a Query Method:</h2>

    <button onclick="queryWithKMeans()">Query with K-Means</button>

    <script>
      function queryWithKMeans() {
        window.location.href = '/home_kmean';
      }
    </script>
  </body>
</html>
```

Hình 56. Mã nguồn file index.html

c) File home_kmean.html nằm trong thư mục templates cho Flask:

```html
<!DOCTYPE html>
<html>
  <head>
    <title>Document Similarity (K-Means K=3)</title>
  </head>
  <body>
    <h1>Document Similarity (K-Means K=3)</h1>
    <button onclick="queryRandomDocumentKMeans()">Query Random Document</button>
    <div id="query-doc">
      {% if query_doc %}
        <h2>Random Document: {{ query_doc.title|join(' ') }}</h2>
        <p>Content:{{ query_doc.content|join(' ') }}</p>
        <p>Cluster Documents:</p>
        <ul>
          {% for doc in cluster_docs %}
            <li>
              <button onclick="showContent('{{ loop.index }}')"> {{ doc.title }} </button>
              <div id="{{ loop.index }}" style="display: none;">{{ doc.content }}</div>
            </li>
          {% endfor %}
        </ul>
      {% endif %}
    </div>
    <button onclick="location.href='/'">Back to Index</button>

    <script>
      function queryRandomDocumentKMeans() {
        window.location.href = '/get_random_document_kmeans';
      }

      function showContent(index) {
        var elem = document.getElementById(index);
        if (elem.style.display === 'none') {
          elem.style.display = 'block';
        } else {
          elem.style.display = 'none';
        }
      }
    </script>
  </body>
</html>
```

Hình 57. Mã nguồn file home_kmean.html

7.7 Tài liệu tham khảo

[1]. Lloyd, Stuart P. "Least squares quantization in PCM." Information Theory, IEEE Transactions on 28.2 (1982): 129-137.

[2]. MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability, 1, 281-297.

[3]. Hartigan, J. A., & Wong, M. A. (1979). A K-means clustering algorithm. Applied Statistics, 28(1), 100-108.

[4]. Jain, A. K. (2010). Data clustering: 50 years beyond K-means. Pattern Recognition Letters, 31(8), 651-666.

[5]. Ali, Heba & Elmogy, Mohammed & Barakat, Shereif. (2016). A BIG DATA PROCESSING FRAMEWORK BASED ON MAPREDUCE WITH APPLICATION TO INTERNET OF THINGS. Ciência e Técnica Vitivinícola. 31.

7.8 Xác nhận của Giảng viên Hướng dẫn, Bộ môn phụ trách

TP. Hồ Chí Minh, ngày 11 tháng 3 năm 2024

Giảng viên hướng dẫn	**Sinh viên thực hiện**
	
	Trần Lê Gia Hiếu

Bộ môn xác nhận

TRƯỜNG ĐẠI HỌC VĂN LANG

KHOA CÔNG NGHỆ THÔNG TIN

PHIẾU NHẬN XÉT VÀ CHẤM ĐIỂM KHÓA LUẬN/ĐỒ ÁN TỐT NGHIỆP

KHÓA 26 – NGÀNH CÔNG NGHỆ THÔNG TIN

Bảng điểm dành cho Giảng viên hướng dẫn

Họ tên sinh viên: **Trần Lê Gia Hiếu** .....

MSSV: **207CT55050** .....

Lớp: **K26-IT14** .....

Tên đề tài: **Mô hình phân cụm dữ liệu để dự báo bài báo mạng** .....

Chuyên ngành: **Công nghệ dữ liệu** .....

Thuộc nhóm: ☐ Đồ án tốt nghiệp ☒ Khóa luận tốt nghiệp

Họ và tên Giảng viên hướng dẫn (GVHD): **Trần Ngọc Việt** .....

1- Nhận xét, đánh giá của GVHD khi sinh viên có hoàn tất các yêu cầu chỉnh sửa của BCN Khoa và Hội đồng chấm KL/ĐA tốt nghiệp *(Ví dụ: Sinh viên không nộp báo cáo và mã nguồn…)*

.....

.....

.....

.....

.....

.....

2- Điểm đánh giá của GVHD:

Bằng số	Bằng chữ

Tp. Hồ Chí Minh, ngày 7 tháng 4 năm 2024

Giảng viên hướng dẫn

(Ký và ghi rõ họ tên)